



山东大学（青岛） · 计算机科学与技术学院

全国大学生计算机系统能力大赛

RespOS

操作系统内核设计文档

Rust · RISC-V 64 · LoongArch 64 · Linux ABI Compatibility

比特工匠队

决赛设计文档 · 2026 年

目 录

1. 概述	8
1.1 项目目标	8
1.2 从启动到用户程序	8
1.3 内核的主要组成	9
1.4 贯穿内核的核心对象	9
1.5 两条贯穿各模块的实现原则	10
1.5.1 用对象边界承载 Linux 语义	10
1.5.2 先准备, 再提交	10
1.5.3 把架构差异收敛在边界内	11
1.6 章节安排	11
2. 进程管理	13
2.1 概述与设计目标	13
2.2 统一任务对象与资源所有权	14
2.2.1 TaskControlBlock	14
2.2.2 强弱引用与生命周期	14
2.3 任务状态与生命周期	16
2.3.1 状态机与调度不变量	16
2.3.2 创建: fork、clone 与共享边界	16
2.3.3 exec: 先准备、再静止、后提交	18
2.3.4 exit、wait 与延迟析构	19
2.4 分层优先级调度	20
2.5 上下文切换与内核栈安全	21
2.6 多核处理器管理	22
2.7 跨模块协作与功能总结	22
3. 中断与异常处理	24
3.1 模块定位	24
3.2 Trap 的基本流程	24
3.3 TrapContext: 统一的可恢复现场	25
3.3.1 RISC-V64 的 TrapContext	25
3.3.2 LoongArch64 的 TrapContext	26
3.3.3 两种上下文的共同语义	26
3.4 中断屏蔽与并发安全	27

3.5 功能与设计总结	27
4. 内存管理	28
4.1 分层对象与核心不变量	28
4.2 双架构地址空间布局	30
4.3 物理页帧与内核堆	30
4.3.1 RV64 动态物理内存发现	31
4.4 VMA 变换与映射类型	32
4.5 缺页处理与按需分配	32
4.6 写时复制	33
4.7 共享文件映射与锁外写回	34
4.8 大 ELF 按需装载	35
4.9 多核 TLB 可见性与生命周期	35
4.10 与其他模块的协作	36
4.11 功能与设计成果总结	36
5. 文件系统	38
5.1 VFS 对象模型	38
5.1.1 File: 一次打开文件的运行时状态	38
5.1.2 FileOp: 统一不同类型文件的使用方式	39
5.1.3 InodeOp: 文件对象的后端能力边界	39
5.1.4 Ext4Inode: InodeOp 的具体实现	40
5.1.5 Dentry、Path 与对象定位	41
5.2 挂载树与路径解析	42
5.2.1 VfsMount 与 Mount	42
5.2.2 namei 路径遍历	42
5.3 ext4 与虚拟文件系统后端	43
5.3.1 ext4 适配层	43
5.3.2 procfs、devfs 与特殊文件	43
5.4 页缓存与持久化写回	44
5.4.1 PageCache 的职责	44
5.4.2 三层写回链	44
5.4.3 与 mmap(MAP_SHARED) 的协作	44
5.5 文件描述符表与生命周期	45
5.5.1 FdTable 与 FdEntry	45
5.5.2 dup、fork、exec 与 close	45

5.6 功能与设计总结	45
6. 进程间通信与信号	47
6.1 概述与机制分工	47
6.2 信号机制	47
6.2.1 线程状态与进程共享状态	47
6.2.2 从产生到 sigreturn 的完整链路	48
6.2.3 可中断等待与架构安全约束	49
6.3 管道：字节流、阻塞与端点生命周期	50
6.3.1 核心对象	50
6.3.2 读写阻塞协议	50
6.3.3 EOF、EPIPE 与 poll 可见性	51
6.4 Futex：用户态快路径与内核竞争路径	52
6.4.1 等待对象与 key	52
6.4.2 single-winner 完成协议	52
6.4.3 requeue 的线性化与当前边界	53
6.5 System V 共享内存	53
6.5.1 段对象与映射生命周期	53
6.5.2 shmat 的失败原子性	54
6.6 跨模块协作与功能总结	55
7. 时钟模块	56
7.1 时间模型与核心数据	56
7.1.1 三种时间尺度	56
7.1.2 TimeSpec 与 deadline	56
7.2 时钟源与时钟中断	57
7.2.1 RISC-V 与 LoongArch 的时钟源	57
7.2.2 Timer trap 的职责	57
7.3 超时管理与任务唤醒	58
7.3.1 deadline registry	58
7.3.2 nanosleep 与阻塞唤醒	59
7.3.3 interval timer 与 POSIX timer	59
7.4 用户态时间接口	59
7.4.1 clock_gettime 与系统时间	59
7.4.2 timerfd：将时间转换为文件事件	60
7.5 与其他模块的协作	60

8. 网络模块	62
8.1 分层架构与责任边界	62
8.2 Socket 对象与 fd 生命周期	63
8.3 回环设备与协议轮询	64
8.4 TCP 套接字与并发监听	65
8.4.1 阻塞、非阻塞与信号中断	65
8.4.2 backlog listener 池	66
8.5 UDP 与 UNIX 域 socket	67
8.5.1 UDP 数据报	67
8.5.2 UNIX 域 socket	68
8.6 网络系统调用与就绪性	68
8.6.1 回环 IPv6 兼容边界	69
8.7 与其他模块的协作	69
8.8 功能与设计成果总结	70
9. 硬件抽象层与架构适配	72
9.1 架构适配的整体结构	72
9.1.1 一套公共调用链，两套底层实现	72
9.1.2 双架构差异总览	73
9.2 地址空间与页表适配	73
9.2.1 共享高半区内核模型	73
9.2.2 RISC-V Sv39 页表	73
9.2.3 LoongArch 页表与 TLB refill	74
9.2.4 页表操作的统一语义	74
9.3 Trap 与特权级切换	74
9.3.1 统一的 trap 三阶段	74
9.3.2 TrapContext 的统一字段与架构差异	75
9.3.3 返回用户态的安全顺序	75
9.4 任务上下文与调度切换	76
9.4.1 TaskContext 与 TrapContext 的分工	76
9.4.2 两套 switch.S 的共同布局	76
9.5 启动流程适配	76
9.5.1 公共启动阶段	76
9.5.2 RISC-V 启动路径	77
9.5.3 LoongArch 启动路径	77

9.6 功能与设计总结	77
10. 设备驱动	79
10.1 概述	79
10.2 块设备驱动	79
10.3 网卡驱动	80
10.4 串口驱动	80
10.5 设备树与设备发现	80
11. 项目参考、AI 使用与第三方代码	81
11.1 按实现主题整理的参考	81
11.1.1 文件系统对象与 ext4 接入	81
11.1.2 地址空间、页表与内存映射	81
11.1.3 进程、线程与调度	82
11.1.4 信号、trap 与用户态返回	82
11.1.5 IPC、同步与阻塞唤醒	82
11.1.6 网络 socket 与设备接口	82
11.2 AI 工具的使用方式	83
11.3 第三方代码与依赖	83
11.4 资料与引用	84
12. 总结与展望	85
12.1 项目成果	85
12.2 实现过程中的收获	86
12.3 构建与复现入口	86
12.4 后续工作	87
12.5 结语	87

1. 概述

RespOS 是一个使用 Rust 编写的教学与竞赛型宏内核，面向全国大学生操作系统比赛中的 Linux 用户态程序，支持 RISC-V64 与 LoongArch64 两种架构。项目的重点不是堆叠系统调用数量，而是把启动、任务、地址空间、文件、网络、信号和设备这些基础部分连接起来，使用户程序能够沿着一条完整的执行链运行。

1.1 项目目标

RespOS 的设计由三个目标共同决定：

目标	具体做法	体现出的结果
支持两种架构	任务、内存、文件和系统调用等部分尽量复用；启动、页表、trap、上下文切换和时钟在架构层分别实现	同一套内核功能可以运行在 RV64 与 LA64 上
兼容 Linux 用户态	syscall 层处理 ABI 参数、返回值和错误码，具体状态由各领域模块维护	musl/glibc 程序可以通过统一的系统调用边界使用内核
保持工程上的可维护性	用明确的数据结构、锁和资源生命周期组织复杂操作，并为失败路径保留回滚空间	fork、exec、mmap、mount、socket 和信号等操作有清晰的模块边界

表 1-1 RespOS 的设计目标

这三个目标相互制约。Linux 兼容要求内核提供稳定的用户态语义，双架构支持要求公共代码不能依赖某一套寄存器或页表格式，而多模块协作又要求文件、内存和任务对象能够安全地共享。因此，本文档重点介绍数据结构、调用关系、资源所有权和并发协议；对于已经约定俗成的接口，只说明它在 RespOS 中如何落地。

1.2 从启动到用户程序

RespOS 采用宏内核结构。内核子系统运行在同一特权级地址空间中，通过对象和模块边界分工；用户程序通过系统调用、文件描述符、信号和网络接口与内核交互。

一次典型的启动和执行过程可以概括为：

架构入口

- 建立早期栈、页表和 trap 环境
- 初始化内存、任务、文件系统、网络 and 时钟
- 创建 initproc 并进入调度
- 用户程序通过 syscall 或硬件 trap 进入内核
- 各领域模块完成操作、阻塞或唤醒
- 返回用户态，或由调度器切换到其他任务

图 1-1 RespOS 的启动与执行链

启动阶段的先后顺序由模块依赖决定: trap 入口需要先具备基本的保存和恢复能力, 内存管理要先于用户任务和大多数内核对象建立, initproc 入队后系统才进入常规调度, 时钟中断则为调度、睡眠和超时机制提供持续的时间事件。

用户程序运行后, 系统调用和硬件异常共同成为进入内核的入口。syscall 层只负责解析用户参数、检查指针和转换返回值, 随后把请求交给 task、mm、fs、net、signal 或 timer 等模块。操作完成后, 内核根据当前任务的状态返回用户态; 如果任务进入阻塞状态, 则由调度器选择其他可运行任务。

1.3 内核的主要组成

RespOS 的主要代码位于 os/src/:

```
os/src/
├── arch/          # RV64/LA64 启动、页表、trap、上下文和时钟
├── task/          # 任务控制块、线程组、调度、futex 和退出回收
├── mm/            # 页帧、MemorySet、VMA、COW 和文件映射
├── fs/            # VFS、ext4、mount、namei、fd、页缓存和 pipe
├── signal/        # pending、handler、siginfo、alt stack 和 sigreturn
├── net/           # socket、TCP/UDP、UNIX socket、loopback 和监听池
├── drivers/       # virtio、串口和设备中断相关代码
├── syscall/       # Linux ABI 参数解析和各领域系统调用入口
└── main.rs        # 公共启动入口
```

图 1-2 RespOS 内核的主要模块

这些目录不是彼此隔离的服务。例如, mmap 同时需要 MM 的 VMA/PTE 管理和 FS 的 FileOp、页缓存; pipe 和 socket 的阻塞需要 task 的等待与唤醒机制; 信号投递要修改用户态 TrapContext, 并由 trap 返回路径恢复; 文件描述符则把普通文件、pipe、socket、timerfd 和设备对象放进同一套用户接口。

1.4 贯穿内核的核心对象

RespOS 将执行状态、地址空间、文件对象和硬件现场分开保存。这样做的好处是, 资源共享关系可以单独表达, 架构差异也不会扩散到公共模块。

对象	主要职责	跨模块关系
TaskControlBlock	保存 tid/tgid、任务状态、内核栈、调度属性和资源引用	持有或关联地址空间、fd 表和信号状态，由 scheduler 管理
MemorySet / VMA	表示用户地址空间、映射权限和文件 backing	被 exec、fork、mmap、缺页和 trap 路径共同使用
TrapContext	保存用户寄存器、返回地址和特权状态	syscall、缺页和信号处理会修改它，返回汇编负责恢复
TaskContext	保存内核态切换点和内核栈信息	由上下文切换代码保存和恢复，连接任务与调度器
FdTable / FileOp	管理 fd 与打开文件状态	pipe、socket、timerfd 和设备文件复用 FileOp 接口
Dentry / InodeOp	分别表示路径中的目录项和后端文件对象	由 namei、mount、ext4、procfs 和 devfs 共同使用
timeout registry	管理 deadline、等待者和到期动作	服务 sleep、futex、信号和 timerfd 的超时唤醒

表 1-2 RespOS 的核心对象

这些对象之间的区别也对应着不同的生命周期。例如，FdTable 保存的是描述符关系，打开文件的偏移和访问状态由共享的 FileOp 持有，因此 dup、fork 和线程创建可以分别表达不同的共享方式。VMA 只描述一段地址范围及其权限，实际页帧在缺页或映射建立时才进入页表。TCB 是调度器管理的执行单元，而用户态寄存器现场保存在其内核栈上的 TrapContext 中，TaskContext 只承担内核态切换所需的状态。

1.5 两条贯穿各模块的实现原则

1.5.1 用对象边界承载 Linux 语义

RespOS 没有把所有行为都堆在 syscall 分支中，而是把用户可以观察到的状态放入稳定对象：任务和线程由 TCB 表示，地址空间由 MemorySet 表示，文件系统把 fd、打开文件、路径、dentry 和 inode 分开，socket、pipe 和 timerfd 则通过 FileOp 接入统一的 fd 生命周期。

因此，syscall 层的职责相对集中：从用户空间取参数，检查范围和权限，调用领域对象，并把结果转换成 ABI 规定的返回值。状态转换、阻塞唤醒和资源释放由具体模块负责。这种分工也使文件映射、socket 阻塞和信号返回等跨模块操作能够沿已有对象接口组合起来。

1.5.2 先准备，再提交

fork、exec、mmap、mount 和 accept 等操作都会同时影响多个对象，单个步骤成功并不代表整个操作已经完成。RespOS 对这类路径采用“先准备、后发布”的组织方式：先创

建对象、检查资源和建立引用关系，确认关键步骤成功后再改变任务状态、挂载关系、页表或 fd 表；如果中途失败，则释放已准备的资源，不发布半完成状态。

例如，exec 要先完成 ELF 装载、地址空间 and 用户栈准备，再替换旧映像；fork 要先完成子任务和资源关系的建立，再把子任务放入可运行队列；阻塞操作则要先将任务和等待条件建立关联，再进入 blocked 状态。这个原则贯穿资源回收、阻塞唤醒和并发错误处理，是各模块之间能够稳定协作的基础。

1.5.3 把架构差异收敛在边界内

RISC-V64 与 LoongArch64 在寄存器、页表根寄存器、异常入口和返回指令上都存在差异。RespOS 没有强行让底层实现完全相同，而是由公共模块使用统一的语义接口，架构目录分别实现启动、页表、trap、任务切换、时钟和中断控制。

例如，公共 syscall 代码通过 get_a0、set_a0、get_sepc 等方法访问上下文，不直接读取某一架构的寄存器数组。公共内存管理也只依赖 map、unmap、query 和刷新等语义，具体页表格式和 TLB 指令由架构层处理。这样，架构适配不会改变上层任务、文件和系统调用的基本模型。

1.6 章节安排

第 2—9 章按照“执行基础—资源管理—外部交互—硬件落地”的顺序展开：

章节	主要问题	内容范围
第 2 章 进程管理	任务如何创建、调度、阻塞和退出？	TCB、线程组、clone/exec、调度器、上下文切换和 SMP 生命周期
第 3 章 中断与异常处理	trap 如何保存现场并安全返回？	TrapContext、syscall、缺页、timer trap、信号交付和双架构返回
第 4 章 内存管理	地址空间如何建立、修改和回收？	VMA/PTE/页 帧 、 lazy allocation、COW、文件映射和 TLB 可见性
第 5 章 文件系统	fd、路径和后端文件系统如何连接？	VFS、 mount/namei、 ext4、 procfs/devfs、页缓存和 fd 生命周期
第 6 章 进程间通信与信号	任务如何传递数据、同步和通知？	signal、pipe、futex、System V 共享内存及其竞争协议
第 7 章 时钟模块	时间事件如何驱动睡眠和超时？	时间尺度、deadline、sleep、POSIX timer 和 timerfd
第 8 章 网络模块	socket ABI 如何连接协议栈和阻塞模型？	smoltcp、 TCP/UDP/UNIX socket、loopback、监听池和 poll
第 9 章 硬件抽象层与架构适配	公共内核如何落到两种指令集？	启动、页表、trap、TaskContext、时钟和架构边界

表 1-3 第 2—9 章的内容安排

阅读后续章节时，可以把 RespOS 看成三条相互交织的链路：任务和 trap 构成执行链，MM、VFS 和 socket 构成资源链，timer、signal、pipe、futex 和网络 poll 构成事件链。它们最终汇合在同一个目标上：让用户程序能够在两种架构上通过接近 Linux 的接口完成加载、运行、阻塞、通信和退出。

2. 进程管理

本章重点介绍 RespOS 的任务模型，以及进程和线程在创建、调度、退出和多核切换中的处理方式。

2.1 概述与设计目标

RespOS 采用与 Linux task 模型相近的统一任务设计：内核只维护一种可调度对象 TaskControlBlock (TCB)，进程与线程的差异由身份和资源共享边界表达，而不是拆成两套控制块。每个任务都有独立的 tid、内核栈、寄存器现场和调度状态；线程组组长满足 tid == tgid，同组线程拥有不同 tid，但共享 tgid。因此，gettid() 标识具体执行线程，getpid() 返回线程组身份，调度器始终按 tid 调度，进程级退出、信号和等待则以线程组或 tgid 为边界。

这个模型需要同时处理几个实际问题：任务对象如何持有资源，clone 如何组合共享语义，阻塞与唤醒如何避免丢失事件，任务切换如何保证旧上下文已经保存，以及退出任务如何在释放当前内核栈的前提下完成回收。表 2-1 对应列出了这些问题的处理方式。

表 2-1 进程管理的设计目标与实现抓手

设计目标	RespOS 的实现	产生的效果
统一进程与线程	TCB + tid/tgid + ThreadGroup	创建、调度、阻塞、信号和退出复用同一套任务接口
明确资源共享边界	Arc<MemorySet>、Arc<FdTable>、共享 handler 表	clone 可按 flag 选择共享或复制，fork/线程语义不混用
保证阻塞唤醒正确	ready/blocked 分离、事件单赢家、发布后复查	覆盖 wait、futex、pipe 和 signal 的 lost-wakeup 窗口
保证多核切换安全	per-CPU idle context、handoff slot、cpu_owner	其他 CPU 不会恢复尚未保存完成的任务上下文
分离退出与析构	Exited 状态、父进程强引用、DEAD_TASKS	wait status 可保留，TCB 与内核栈在安全栈上延迟释放

2.2 统一任务对象与资源所有权

2.2.1 TaskControlBlock

TCB 不是简单的“寄存器集合”，而是一个任务从创建到析构的资源所有权中心。代码片段 2-1 摘录了当前实现中最能说明身份、调度、进程关系、资源共享和信号状态的字段；未列出的 UID/GID、调度属性、资源限制和计时字段遵循相同的所有权原则。

代码片段 2-1 TaskControlBlock 的代表性字段

```
// os/src/task/task.rs (节选)
pub struct TaskControlBlock {
    kernel_stack: KernelStack,
    tid: RwLock<TidHandle>,
    tgid: AtomicUsize,

    thread_group: Arc<SpinLock<ThreadGroup>>,
    group_exiting: Arc<AtomicBool>,
    terminate_requested: AtomicBool,
    task_status: SpinLock<TaskStatus>,
    cpu_owner: AtomicUsize,

    parent: Arc<SpinLock<Option<Weak<TaskControlBlock>>>>,
    children: Arc<SpinLock<BTreeMap<usize, Arc<TaskControlBlock>>>>,
    exited_children: Arc<SpinLock<BTreeSet<usize>>>,

    memory_set: Arc<RwLock<MemorySet>>,
    fd_table: SpinLock<Arc<FdTable>>,

    sig_pending: SpinLock<SigPending>,
    sig_stack: SpinLock<SignalStack>,
    sig_handler: Arc<SpinLock<SigHandler>>,

    interruptible: AtomicBool,
    waiting_for_child: AtomicBool,
    interrupted: AtomicBool,
}
```

代码片段 2-1 体现了三种并发手段的分工。原子字段用于频繁读取且状态较小的身份或协议位，例如 tgid、终止请求和 CPU owner；SpinLock 保护需要整体一致更新的任务状态、父子集合和信号状态；RwLock<MemorySet> 允许地址空间查询并发进行，同时把页表或 VMA 修改收敛到写侧。trap context 并不是 TCB 中的独立字段，而是固定放在该任务内核栈顶端；TaskContext 位于其下方，由 __switch 保存和恢复。

2.2.2 强弱引用与生命周期

RespOS 根据对象是否应延长任务生命周期选择 Arc 或 Weak。如表 2-2 所示，线程组和全局任务索引只保存 TCB 的弱引用，避免“索引持有对象、对象又持有索引关系”造成无法析构；父任务的 children 则有意持有子进程 leader 的强引用，使子进程退出后仍能保留 wait status，直到 wait4 提交回收。

表 2-2 任务相关对象的所有权与共享范围

对象或状态	创建者与共享范围	更新/释放方式	用户可见语义
KernelStack、trap context、TaskContext	每个 TCB 独占	CPU 切到 idle 栈后随 TCB 延迟析构；slot 可复用	每个线程可独立陷入内核和被调度
ThreadGroup	同组线程共享，成员表保存 Weak<TCB>	创建线程时加入，线程退出或 exec 清理时移除	tid 不同但 tgid 相同，组级操作作用于全部线程
MemorySet	fork 默认建立 COW 子空间；CLONE_VM 可共享	exec 替换，最后一个所有者退出时回收	决定进程间内存隔离或线程间地址空间共享
FdTable	fork 复制描述符表；CLONE_FILES 或线程创建时共享	close/exec/exit 更新；exec 先私有化再处理 CLOEXEC	决定一方 close 是否影响另一方的 fd 表
SigPending、mask、备用信号栈	每线程独占	投递、sigprocmask、sigreturn 和 exec 更新	每个线程可独立屏蔽、等待和处理信号
SigHandler	同一线程组共享	sigaction 更新，exec 重置用户 handler	任一线程修改 handler 后全进程可见
TASK_MANAGER	全局 tid -> Weak<TCB>	创建时加入，逻辑退出时移除	kill/tkill/tgkill、调度和清理路径可按 tid 定位任务
children	线程组共享，保存子进程 leader 的 Arc<TCB>	子进程创建时加入，wait4 成功后删除	zombie 状态在父进程读取前不会丢失

图 2-1 展示了这些对象之间的关系。一个“进程”由线程组身份和一组共享资源共同构成；TCB 才是真正进入调度器的执行单元。

图 2-1 进程、线程与资源对象关系

进程 (tgid)

├ ThreadGroup —Weak—> TCB(tid = tgid, leader)

├ TCB(tid = n1)

└ TCB(tid = n2)

├ Arc<MemorySet> <—— 同组线程通常共享

├ Arc<FdTable> <—— 同组线程共享；fork 默认复制表

├ Arc<SigHandler> <—— sigaction 进程级可见

└ children: Arc<TCB> —> 保留子进程 wait status


每个 TCB 独占: KernelStack + TrapContext + TaskContext + SigPending + SignalStack

2.3 任务状态与生命周期

2.3.1 状态机与调度不变量

RespOS 使用 Ready、Running、Blocked、Stopped 和 Exited 五种任务状态。图 2-2 中最重要的不变量是：同一个 tid 不能同时出现在 ready queue 与 blocked_tasks 中；多核取任务时，出队与 CPU owner 认领必须处于同一调度临界过程，避免其他 CPU 或唤醒者看到“已出队但仍可再次发布”的中间状态。

图 2-2 任务状态转换



队列锁只能保证容器本身不被并发破坏，不能自动保证状态机正确。RespOS 因此还通过 task_index 阻止重复入队，通过 blocked_tasks 保存真正睡眠的任务，并在 debug 构建中检查队列、索引和状态三者是否一致。

2.3.2 创建：fork、clone 与共享边界

fork、线程创建和 vfork 最终都收敛到 sys_clone()。系统调用层校验 flag，设置父/子 tid、TLS、用户栈和子任务返回值；TaskControlBlock::clone_() 构造身份及资源关系；最后由调度器发布新任务。表 2-3 只列出会改变对象身份或共享关系的关键 flag，常规 ABI 标志不在此展开。

表 2-3 clone 关键标志与当前共享语义

标志	未设置	设置后	当前实现边界
CLONE_THREAD	新 tid 同时成为新 tgid, 创建新线程组	新 tid 加入调用者线程组并沿用 tgid	要求 CLONE_SIGHAND, 后者又要求 CLONE_VM
CLONE_VM	通过 COW 建立子 MemorySet	共享同一个 MemorySet	非线程 vfork 为保护父映像, 当前仍建立 COW 子空间
CLONE_FILES	新进程复制 descriptor 表	共享同一个 FdTable	同组线程无条件共享 fd table
CLONE_VFORK	父任务可在 child 发布后继续	父任务阻塞到 child 成功 exec 或 exit	已实现同步边; 未直接共享父地址空间

代码片段 2-2 是资源选择的核心。这里的“复制 fd table”并不复制每个 open-file description: 新表中的 FdEntry 仍持有相同的 Arc<FileOp>, 因此 fork 后父子可以独立 close 或设置 CLOEXEC, 但共享文件偏移和管道端点; CLONE_FILES 则连 descriptor 表本身也共享。

代码片段 2-2 clone 的地址空间与 fd table 选择

```
// os/src/task/task.rs
let memory_set = if flags.share_user_vm() {
    self.memory_set.clone()
} else {
    Arc::new(RwLock::new(MemorySet::from_existed_user(
        &mut self.memory_set.write(),
    )))
};

let fd_table = if is_thread || flags.contains(CloneFlags::CLONE_FILES) {
    self.fd_table.lock().clone()
} else {
    FdTable::from_existed_user(&self.fd_table.lock())
};
```

普通 fork 的内存复制采用 COW。MemorySet::from_existed_user() 复制 VMA 元数据; 未驻留的 lazy 页继续保持未分配, 只读页和共享页复用原 frame, 私有可写驻留页在父子两侧转为 COW。实现先完成子页表构造, 再修改父页表权限, 使中途 ENOMEM 不会在父地址空间留下映射空洞。这一机制把 fork 成本从“复制整个地址空间”降为“复制元数据并按首次写入付费”。

vfork 的难点不只是“让父任务睡眠”, 而是建立不会丢失的一次性同步边。若先发布 child 再登记 parent, child 可能在另一 CPU 上立即 exec 并发送唤醒, 而 parent 尚未进入 blocked 集合。RespOS 按图 2-3 固定发布顺序, 并用 vfork_parent: Option<Weak<TCB>> 保证 exec/exit 只释放一次。

图 2-3 vfork 的一次性同步顺序

```
parent: new_task.set_vfork_parent(parent)
      -> prepare_current_task_blocked(parent)
      -> add_task(child)
      -> switch_to_next_task()

child : exec 完整提交 或 exit
      -> release_vfork_parent()
      -> wakeup_task(parent.tid)
```

Linux vfork 还要求 child 在 exec/exit 前直接使用父地址空间。RespOS 当前将地址空间保存在 Arc<RwLock<MemorySet>> 中，而 exec 通过替换锁内的 MemorySet 安装新映像；若非线程 vfork 直接共享该对象，child exec 会同时替换父任务可见的映像。因此当前实现保留了父子同步语义，但用 COW 子空间隔离映像替换。这是明确的数据结构边界，而不是将当前行为误写成完整 Linux vfork。

2.3.3 exec：先准备、再静止、后提交

exec 的目标是一次性替换整个进程映像，而不是在旧地址空间上逐段修补。RespOS 将文件 ELF 加载收敛到 MemorySet::try_from_elf_file()，将安装阶段收敛到 install_exec_image()，按表 2-4 的四个阶段推进。

表 2-4 exec 映像替换阶段与正确性保证

阶段	主要工作	正确性保证
准备新映像	校验 ELF，创建新 MemorySet，布置 argv/envp/auxv	失败发生在提交前，旧程序仍保持完整
静止 sibling	设置 terminate_requested, 从调度器摘除并等待 cpu_owner 释放	其他 CPU 不再执行旧用户映像
提交映像	替换 MemorySet、激活页表、重建 trap context	PC、SP、寄存器与新地址空间同时生效
提交外围状态	私有化 fd table、执行 CLOEXEC、重置信号状态、释放 vfork parent	父任务只会在 exec 可见状态完整后恢复

图 2-4 展示了多线程 exec 中的 stop/ack 协议。sibling 的 robust list 和 clear-child-tid 保存的是旧映像用户地址，因此必须在地址空间替换前处理；仅从 ready queue 删除任务也不够，因为它可能仍在远端 CPU 上执行。远端 CPU 只有在 __switch 保存完上下文并回到 per-CPU idle 栈后才释放 cpu_owner，publish_saved_handoff() 对已经请求终止的任务不再重新发布。

图 2-4 多线程 exec 的静止与提交顺序

```
准备完整新映像
└-> request_termination(siblings)
```

```
└> remove_task(siblings)
    └> 等待所有 cpu_owner 释放
        └> 在旧 MM 中清理 robust list / clear-child-tid
            └> 替换 MemorySet 与 TrapContext
                └> CLOEXEC + signal reset + 唤醒 vfork parent
```

文件式 exec 还采用 private file-backed VMA 按需加载主程序的 PT_LOAD。内核只读取 ELF header、program header 和 PT_INTERP 元数据，元数据前缀上限为 1 MiB；程序页面在首次访问时按页读入。与早期 read_all() 整文件载入相比，这一设计避免约 45 MiB 的 cargo 可执行文件在内核堆与用户页中重复占用。argv 和 envp 每组允许最多 4096 项，同时以每组 1 MiB 累计字节限制约束内核分配，既支持真实工具链，又避免无界输入。

当前 exec 只允许线程组 leader 执行，以避免非 leader 替换映像后重新组织 tgid 与父子关系；动态链接器仍采用整文件读取，尚未复用主程序的按需路径。这两个边界不影响上述提交顺序，但限定了当前兼容范围。

2.3.4 exit、wait 与延迟析构

RespOS 将“停止执行”“向父进程保留退出状态”和“释放 TCB/内核栈”分成三个不同时间点。表 2-5 说明了每个时间点的资源处理职责；这种分离是 wait 语义和内核栈安全共同要求的结果。

表 2-5 退出与回收的分阶段职责

时间点	状态变化	主要处理
线程逻辑退出	当前 TCB 变为 Exited	清理 robust list、clear-child-tid、futex waiter，并从调度器/线程组/任务索引摘除
线程组退出	原子选出唯一 teardown owner	静止 sibling，处理共享 MM/fd/timer，托管孤儿，leader 向父进程发布 SIGCHLD 与 wait status
wait4 成功	父任务删除 children[child_tid]	先 copyout status/rusage，成功后再删除 zombie 并累计子进程时间
安全栈上析构	idle loop 清空 DEAD_TASKS	最终 drop TCB，回收内核栈 slot；已有内核页表映射保留供复用

exit_group() 和致命信号共用组级退出路径。共享的 group_exiting 通过 compare-exchange 选出唯一清理者，防止多个 CPU 重复清空 fd table、回收地址空间或通知父进程。组级退出沿用 exec 的 stop/ack 协议：先阻止 sibling 再次被 claim，再等待远端 owner 释放，最后处理共享资源。

wait4 采用 prepare/copyout/commit。内核先将 status 和 rusage 写回用户空间，所有 copyout 成功后才从 children 删除 child 并提交子进程时间；用户指针无效时，父任务可修正参数后再次 wait，不会丢失退出状态。SMP 下实际 waiter 可能是父线程组中的

任意线程，因此子进程退出会唤醒所有设置了 `waiting_for_child` 的成员；`waiter` 在发布 `blocked` 后还会复查 `exited_children` 和中断标志，覆盖“扫描完成、正式睡眠之前 `child` 恰好退出”的窗口。

图 2-5 展示了父子回收与本任务析构两条并行生命周期。父进程回收的是用户可见的 `zombie` 状态，`idle loop` 回收的是已经不再执行的内核对象，两者不能互相替代。

图 2-5 退出通知、`wait` 与最终析构

```
child 逻辑退出 → Exited + SIGCHLD → parent wait4 copyout → children 删除
|
└→ 当前 CPU 切到 idle 栈 → DEAD_TASKS → cleanup_dead_tasks → drop
TCB/栈 slot
```

2.4 分层优先级调度

RespOS 的调度器没有照搬 Linux CFS，而是采用便于检查的分层固定优先级队列，在同一框架下承载实时任务、普通任务和低优先级后台任务。表 2-6 描述了当前选择顺序和兼容边界。

表 2-6 调度策略与就绪队列

任务类型	队列组织	选择顺序	当前语义边界
SCHED_FIFO / SCHED_RR	优先级 1~99 的 RT 队列	数值越大越优先，同级 FIFO	周期时钟当前会重新排队两者，尚未完整区分 Linux FIFO 与 RR
SCHED_OTHER / SCHED_BATCH	nice -20~19 的 40 个普通队列	nice 越小越优先，同级轮转	固定优先级模型，不维护 CFS 虚拟运行时间
SCHED_IDLE	单独的 idle 队列	RT 与普通队列均无可运行任务时选择	用于最低优先级后台工作

代码片段 2-3 展示了调度器的核心容器。RT 和普通队列各有位图，选择任务时可以跳过空优先级；`task_index` 记录 `tid` 当前所在的 `ready queue`，既支持快速删除，也用于拒绝重复入队；真正睡眠的任务保存在独立的 `blocked_tasks` 中。

代码片段 2-3 分层调度器的数据结构

```
// os/src/task/scheduler.rs
pub struct Scheduler {
    rt_queues: Vec<VecDeque<Arc<TaskControlBlock>>>,
    normal_queues: Vec<VecDeque<Arc<TaskControlBlock>>>,
    idle_queue: VecDeque<Arc<TaskControlBlock>>,
    rt_bitmap: u128,
    normal_bitmap: u64,
    task_index: HashMap<usize, ReadyQueue>,
}
```

```
blocked_tasks: HashMap<usize, Arc<TaskControlBlock>>,
}
```

时钟抢占和主动 yield 都会经过 per-CPU handoff，再由 idle loop 将仍为 Running 且未被请求终止的任务改为 Ready 并放回队尾。因此同优先级内形成简单 round-robin，不同优先级之间仍保持 RT → normal → idle 的严格选择顺序。

2.5 上下文切换与内核栈安全

RespOS 采用同步有栈的内核任务切换。用户态 trap 保存完整的 TrapContext；真正的内核任务切换以函数调用为边界，只需保存调用约定中的 callee-saved 寄存器、线程指针和页表 token。代码片段 2-4 给出了跨架构共用的 TaskContext 表示：RISC-V 的 s0-s11 与 LoongArch 的对应保存寄存器统一落在 s[12] 中，架构汇编负责具体映射。

代码片段 2-4 内核任务上下文

```
// os/src/task/context.rs
#[repr(C, align(16))]
pub struct TaskContext {
    ra: usize,
    tp: usize,
    s: [usize; 12],
    mmu_token: usize,
    _padding: usize,
}
```

内核栈按 slot 分配，相邻 slot 之间保留一个 guard page。任务析构时回收 slot，但保留全局内核页表中的栈映射；后续任务复用同一 slot 时无需频繁修改共享内核页表。这一选择把短进程压力下的页表扰动转化为有限 slot 的循环复用。

多核切换的关键约束是：正在旧 CPU 上执行的任务不能直接加入全局 ready queue。早期“先入队、再 __switch”的顺序允许另一 CPU 立即取到该任务，恢复一份尚未保存完成的 context。RespOS 通过 per-CPU handoff 和 cpu_owner 将顺序固定为图 2-6 所示。

图 2-6 context-save 到 ready-publication 的 handoff 协议

旧 CPU / task 栈	旧 CPU / idle 栈	新 CPU
Running task		
└> 移入本 CPU handoff		
└> __switch 保存 context	└> publish_saved_handoff	
	└> 若仍可运行: set_ready + enqueue	
	└> release cpu_owner	
		└> claim owner
		└> __switch 恢
复		

handoff 保证 ready 发布发生在上下文保存之后, cpu_owner 则保证新 CPU 的 claim 发生在旧 CPU 明确释放之后。即使 wakeup 在保存期间提前到达, 任务也只会留在 ready queue 中等待 owner 释放, 不会被恢复两次。

2.6 多核处理器管理

RV64 的每颗 CPU 都有独立的 Processor、idle task 和 handoff slot; LoongArch 当前仍以单核处理器数组入口运行。没有可运行任务时, RV64 CPU 先发布 idle 状态, 再检查一次全局 ready queue, 仍为空才打开本地 timer 中断并进入 WFI。第二次检查覆盖了“首次取队列失败”到“CPU 正式睡眠”之间的新任务入队窗口。

图 2-7 给出了跨核唤醒链路。IPI 只负责唤醒 WFI 中的 CPU, 任务选择仍由 idle loop 完成, 从而避免在中断上下文中执行复杂调度逻辑。

图 2-7 多核任务唤醒与定向 IPI

```
事件到达
└> blocked_tasks 删除 tid
    └> task.set_ready + 加入原优先级队列
        └> 按 CPU affinity 选择在线 idle hart
            └> IPI 唤醒
                └> idle loop fetch_for_cpu + claim cpu_owner
```

affinity 必须同时约束“谁能取任务”和“唤醒谁”。fetch_for_cpu() 会在优先级队列内跳过当前 CPU 不允许或 owner 尚未释放的任务, 同时保留其相对位置; 任务入队和 owner 释放后的 kick 也只面向 affinity 允许的在线 idle CPU。后一处补发 kick 覆盖了第一次 IPI 到达过早、任务仍被旧 owner 持有的窗口。

当前调度器使用全局锁和全局 run queue。这使 ready/blocked/index 不变量集中且容易审查, 也支持当前 RV64 多核正确性; 当 CPU 数继续增长时, 全局锁争用会成为引入 per-CPU run queue 与负载均衡的主要依据。

2.7 跨模块协作与功能总结

进程管理并不独立完成所有任务语义, 而是为内存、文件、信号、时钟和 IPC 提供统一生命周期边界。表 2-7 总结了这些协作关系及本章所证明的设计成果。

表 2-7 进程管理的跨模块接口与设计成果

协作模块	进程管理提供或依赖的接口	已形成的能力
内存管理	MemorySet 的 COW clone、exec 替换、active-hart 标记与回收	fork 延迟复制、文件 ELF 按需加载、SMP 地址空间安全切换
文件系统	FdTable 复制/共享、CLOEXEC、退出清表	fork 共享 open-file 状态, exec 不误关共享父表, pipe EOF 可按最后引用产生
信号	每线程 pending/mask、组共享 handler、可中断等待	kill/tkill/tgkill、停止/继续/致命信号与 wait 唤醒接入统一 TCB
futex/pipe/wait	blocked 注册、single-winner 完成、signal interrupt	事件、超时、signal 和退出竞争时不重复唤醒或永久睡眠
时钟与 SMP	抢占入口、per-CPU idle、affinity IPI、cpu_owner	分层调度、跨核唤醒和 context handoff

在 RespOS 中，进程管理并不是一组彼此独立的系统调用。tid/tgid 负责定义身份，Arc/Weak 负责表达所有权，scheduler 负责发布状态，handoff/owner 负责划定多核切换边界，wait 与 DEAD_TASKS 分别处理用户可见的回收和内核对象析构。fork/exec/exit、信号和 IPC 都建立在这套任务模型上。

3. 中断与异常处理

本章重点介绍 trap 的入口、分发和返回过程，以及 RISC-V64 与 LoongArch64 在现场保存和特权级返回上的差异。

3.1 模块定位

中断与异常处理是用户程序进入内核的入口，也是时钟、系统调用、缺页和进程抢占等机制的连接点。RespOS 将中断与异常处理过程分为两层：架构相关的入口与返回代码负责完成寄存器保存、特权级切换和硬件状态恢复；架构无关的 Rust 代码负责识别异常原因，并调用系统调用、内存管理、信号和调度模块。

这样，系统调用、缺页和定时器等处理逻辑可以共享，而入口汇编仍然保留各自架构的硬件细节。图 3-1 展示了一次用户态 trap 的处理路径。




图 3-1 用户态 trap 的入口、分发与返回路径

3.2 Trap 的基本流程

一次 trap 可以概括为“入口保存、Rust 分发、后置检查、返回恢复”四个阶段。系统调用、缺页、非法指令和断点属于同步异常，定时器和软件中断则可能在程序执行过程中异步到达；无论来源如何，最终都进入同一条处理链路。

首先，硬件将返回地址和异常原因写入架构寄存器，并跳转到预先配置的 trap 入口。入口汇编切换到内核栈，保存通用寄存器和返回所需的状态，构造 TrapContext，再调用

Rust 侧的 `trap_handler`。RISC-V 和 LoongArch 使用的寄存器与入口指令不同，但这一阶段都只负责建立一份完整、可恢复的内核现场。

随后，`trap_handler` 读取硬件原因并完成分发：系统调用交给 `syscall` 层，缺页交给 `MemorySet`，定时器负责设置下一次触发并推进超时处理，软件中断负责响应核间通知。处理结果可能是修改 `TrapContext` 后继续执行，也可能是向用户任务递送信号、结束任务，或在安全点进入调度器。用户态异常通常通过信号或退出隔离应用故障；内核态发生非法指令、缺页或系统调用则按内核错误处理。

在返回前，内核统一完成待处理信号和必要的调度检查。若当前任务仍可运行，返回汇编就按照固定布局恢复 `TrapContext`，切回用户态 `trap` 入口，并执行 RISC-V 的 `sret` 或 LoongArch 的 `ertn`；若任务已经阻塞、退出或被抢占，则先由调度器切换到其他任务，再从新任务的现场恢复。系统调用返回值、缺页修复结果以及信号处理后的用户态控制流，最终都通过这份可修改的现场生效。

3.3 TrapContext：统一的可恢复现场

`TrapContext` 描述了用户程序的运行状态，定义了入口汇编与 Rust 处理逻辑之间的数据契约。入口汇编按照固定顺序把寄存器保存到内核栈，Rust 代码通过这个结构读取系统调用参数、修改返回值或调整返回地址，最后由返回汇编按照相同布局恢复。

3.3.1 RISC-V64 的 TrapContext

RISC-V64 的上下文需要保存通用寄存器、浮点寄存器、浮点控制状态以及用户态返回所需的 `sstatus` 和 `sepc`：

```
#[repr(C)]
#[derive(Debug, Clone, Copy)]
pub struct TrapContext {
    pub x: [usize; 32],
    pub sstatus: Sstatus,
    pub sepc: usize,
    pub f: [usize; 32],
    pub fcsr: usize,
    _padding: usize,
}
```

代码片段 3-1 RISC-V64 的 `TrapContext` 结构

其中，`x[10]` 是 RISC-V ABI 的 `a0`，既用于传递第一个参数，也用于接收系统调用返回值；`x[2]` 是用户栈指针 `sp`；`sepc` 保存 `trap` 返回地址，`sstatus` 保存返回时需要恢复的特权级和中断状态。浮点寄存器也属于用户程序的执行现场，因此入口和返回路径需要一并保存、恢复。

创建用户初始上下文时，RespOS 将 sstatus.SPP 设置为 User，并关闭保存现场期间的 SIE；同时设置入口地址和用户栈指针。对于 Linux ABI 程序，a0 等参数由用户栈上的启动数据解释；内置教学程序则可以使用寄存器传递 argc、argv 等参数。

3.3.2 LoongArch64 的 TrapContext

LoongArch64 的特权状态和返回地址分别由 prmd 与 era 表示，当前上下文结构保存通用寄存器以及这两个架构状态寄存器：

```
#[repr(C)]
#[derive(Debug, Clone, Copy)]
pub struct TrapContext {
    pub x: [usize; 32],
    pub prmd: usize,
    pub era: usize,
}
```

代码片段 3-2 LoongArch64 的 TrapContext 结构

LoongArch 的 a0 对应 x[4]，栈指针对应 x[3]，系统调用号位于 x[11]，六个参数位于 x[4..10]。prmd 中的 PPLV 和 PIE 位用于记录异常前的特权级及返回后的中断状态。

创建 LoongArch 用户上下文时，RespOS 将 prmd 初始化为用户态并允许异常返回后重新开启中断，再设置 era 和用户栈指针。与 RISC-V 一样，Linux ABI 程序的启动参数从用户栈获取；内置程序则由寄存器传入启动参数。

3.3.3 两种上下文的共同语义

两种结构在字段层面并不完全相同，但它们都提供了访问返回值、用户栈和返回 PC 的语义接口。

图 3-2 总结了 TrapContext 在一次 trap 中的生命周期。




图 3-2 TrapContext 在一次 trap 中的生命周期

3.4 中断屏蔽与并发安全

trap 处理不仅要识别事件, 还要避免处理过程被同类事件破坏。RespOS 为两种架构提供统一语义的 InterruptGuard: 构造时保存当前中断使能状态并关闭中断, 离开作用域时仅在原先开启的情况下恢复。这样既能保护临界区, 也不会无条件打开调用者原本关闭的中断。

场景	RISC-V 机制	LoongArch 机制	共同语义
trap 入口	配置 stvec, 进入内核入口	配置 EENTRY, 进入内核入口	先建立内核可用的保存环境
中断总开关	sstatus.SIE	CRMD.IE	由 guard 保存并按原状态恢复
用户态返回	sret 根据 sstatus 返回	ertn 根据 PRMD/ERA 返回	只在现场完整后恢复用户态
定时器状态	SBI 设置下一次触发	清除定时器状态并配置下一次触发	重新武装后再执行计时器服务

表 3-2 双架构 trap 控制语义对照

RISC-V 在返回路径强调顺序性约束: 恢复寄存器的中间阶段优先保持 SIE 关闭, 待通用寄存器和浮点寄存器全部恢复后, 才切换回用户态。否则定时器可能在现场尚未恢复完成时再次进入 trap, 导致使用半恢复状态的寄存器。LoongArch 则在 ertn 前准备好 PRMD、ERA、用户态入口和栈切换信息, 再由硬件完成特权级返回。

设备外部中断的具体控制由架构和驱动层共同承担: 架构层负责把硬件中断送入统一 trap 路径, 驱动层负责识别设备、清除设备状态并完成请求。这样可以把“如何进入内核”和“哪个设备需要服务”分开, 避免 trap 分发器依赖具体设备实现。

3.5 功能与设计总结

设计点	实现方式	对系统的作用
统一入口	架构汇编保存现场, Rust 统一分发	系统调用、异常和中断共享清晰的边界
可修改现场	TrapContext 作为返回上下文	返回值、信号、抢占都可通过同一机制生效
用户/内核分流	用户错误转信号或退出, 内核错误 panic	隔离应用故障, 尽早暴露内核不变量破坏
架构复用	共享处理策略, 保留各自 CSR 与返回指令	支持 RISC-V 与 LoongArch 的一致功能语义
返回安全	固定保存布局、屏蔽顺序和栈切换协议	避免重入、现场损坏和错误特权级返回

中断与异常模块承担了一条完整的控制流: 将硬件事件转换为内核服务, 把服务结果写回可恢复现场, 最后将控制权安全地交还给任务。内存、时钟、进程、信号和驱动模块则分别在这条闭环的分发节点上实现各自功能。

4. 内存管理

本章介绍物理页分配、进程地址空间、缺页与文件映射，并说明多核环境下页表修改的同步方式。

RespOS 采用“MemorySet 拥有地址空间语义”的设计，因为单独管理页表只能说明 CPU 当前看见什么，无法表达一段虚拟地址是否合法、是否按需分配、来自哪个文件，以及由谁回收。因此，内存层将 VMA（Virtual Memory Area）、PTE 和物理页帧组成一个完整的所有权模型，并让 mmap、fork、exec、用户指针访问与进程退出共用这套规则。

4.1 分层对象与核心不变量

RespOS 将“虚拟地址承诺”、“硬件映射状态”和“物理内存所有权”分层表示。如图 4-1 所示，一个已声明但尚未访问的 lazy VMA 可以没有 PTE 和页帧；只有页面真正被访问后，后两层状态才建立。




图 4-1 MemorySet、VMA、PTE 与驻留页的层次关系

表 4-1 列出了这些对象的职责和生命周期。这里需要特别区分 VMA 和页表：VMA 决定一次访问是否合法、缺页能否修复，PTE 才表示当前 CPU 已经看到的映射。

表 4-1 地址空间核心对象

对象	表达的概念	拥有的状态	创建、共享与释放
MemorySet	一个进程地址空间	页表、VMA 集合、brk、mmap_start	exec 构建，CLONE_VM 任务共享，最后一个引用释放
MapArea	一段连续 VMA	VPN 范围、权限、共享标志、文件偏移、驻留页	ELF loader、brk、mmap 创建；munmap/mprotect/mremap 切分
PTE	硬件页级映射	PPN、R/W/X/U 和 COW 等标志	建图或缺页时创建，改权限时更新，解除映射时删除
FrameTracker	一个 4 KiB 物理页帧的所有权	PPN；共享页由 Arc 表达引用	分配时清零，最后一个所有者销毁时自动归还

代码片段 4-1 地址空间与 VMA 的关键字段

```
// os/src/mm/memory_set.rs (节选)
pub struct MemorySet {
    pub brk: usize,
    pub heap_bottom: usize,
    pub mmap_start: usize,
    pub page_table: PageTable,
    areas: Vec<MapArea>,
    #[cfg(target_arch = "riscv64")]
    active_hart_mask: AtomicUsize,
}

struct MapArea {
    vpn_range: VPNRange,
    data_frames: BTreeMap<VirtPageNum, Arc<FrameTracker>>,
    map_type: MapType,
    map_perm: MapPermission,
    shared: bool,
    locked: bool,
    file_backing: Option<FileBacking>,
    shm_attach_id: Option<usize>,
    // 另有 wipe_on_fork / dontfork 等 VMA 语义标志
}
```

代码片段 4-1 中的 areas 是按起始 VPN 排序的 VMA 序列，data_frames 则是稀疏的驻留页集合。这种“范围元数据 + 实际工作集”的表示使大范围 lazy VMA 不需要按虚拟跨度预先创建管理对象，退出回收也只遍历已驻留页。

RespOS 在 debug 构建中对上述模型执行结构自检：VMA 必须有序、非空且不重叠；data_frames 的 VPN 必须落在所属 VMA 中并对应有效 PTE；用户 VMA 必须带 U 权

限；COW 页不能同时可写；shared VMA 不能误入私有 COW 路径。这些断言把“实现约定”变成了可执行的不变量。

4.2 双架构地址空间布局

RespOS 在 RV64 和 LA64 上保持共享的 39 bit 虚拟地址模型，因为这能让 MemorySet、VMA 和大部分内核映射逻辑在两个架构上共用。两种架构的内核都链接到 0xffff_ffc0_0000_0000 起始的高半区，用户映射位于低半区，页大小均为 4 KiB；具体差异见表 4-2。

表 4-2 RV64 与 LA64 内存布局对比

项目	RISC-V 64	LoongArch 64
内核虚拟基址	0xffff_ffc0_0000_0000	0xffff_ffc0_0000_0000
内核物理入口	0x8020_0000	0x0020_0000
用户 mmap 区间	0x20_0000_0000 ~ 0x22_0000_0000	相同
用户信号返回跳板	0x3f_fff_e000	相同
内核堆	64 MiB	48 MiB
物理内存上限来源	OpenSBI 传入 FDT 的 /memory/reg	板级静态配置

内核页表对 text、rodata、data、bss 分别设置 RX、R、RW、RW 权限，其余 RAM 和 MMIO 按 KERNEL_BASE + physical_address 的固定偏移映射。因此，内核可以由 PPN 直接得到访问页帧的高半区虚拟地址，页表页构造、COW 复制和用户拷贝无需临时建立 kmap。

LoongArch 启动时确实会使用早期低地址可达路径，但进入公共内存初始化后会激活高半区内核页表并关闭低地址 direct map。因而，当前实现不是“RV64 使用高半区页表、LA64 长期使用 DMW 内核”的两套公共模型；架构差异主要保留在页表格式、MMU 寄存器与 TLB 操作后端中。

4.3 物理页帧与内核堆

RespOS 将物理页帧分配和内核小对象分配彻底分开。页表页、用户驻留页和内核映射页最终需要 4 KiB 物理帧；Vec、Arc、BTreeMap 等 Rust 对象则从 buddy system 管理的固定内核堆中获得可变大小空间。

代码片段 4-2 FrameTracker 的 RAII 回收

```
// os/src/mm/frame_allocator.rs (节选)
pub struct FrameTracker {
    ppn: PhysPageNum,
}

impl FrameTracker {
    pub fn new(ppn: PhysPageNum) -> Self {
        let mut frame = Self { ppn };
    }
}
```



```

        frame.clear();
        frame
    }
}

impl Drop for FrameTracker {
    fn drop(&mut self) {
        FRAME_ALLOCATOR.lock().dealloc(self.ppn());
    }
}

```

代码片段 4-2 体现了页帧所有权的两个安全性质：新页必先清零，避免前一个使用者的数据泄漏；页帧随最后一个 FrameTracker 所有者销毁而归还，COW 和共享映射只需通过 Arc<FrameTracker> 表达共享，无需另外维护一套手工页帧引用计数。底层页帧分配器是 StackFrameAllocator：优先复用回收栈中的 PPN，再从未分配区间线性取页；它不是 buddy allocator。

内核堆使用 buddy_system_allocator::LockedHeap，但在外层增加了 IrqSafeHeap。这一包装不仅使用自旋锁串行化不同 CPU，还在每次分配、释放以及直接获取堆 guard 时关闭本地中断。之所以需要第二层保护，是因为跨 CPU 自旋锁不能阻止同一 CPU 在持锁期间被 timer interrupt 打断并再次申请堆；恢复中断前先释放堆锁，从而避免同核重入自锁。

4.3.1 RV64 动态物理内存发现

RISC-V 的物理内存管理采用“最大可达窗口”与“实际可分配范围”分离的设计。早期根页表预留最多 8 GiB QEMU RAM 的可达窗口，启动 hart 再从 OpenSBI 传入的 FDT / memory/reg 取得本次启动的真实内存末址。页帧分配器只管理真实范围，因此既能使用 8 GiB 负载，也不会在 256 MiB 配置下误分配不存在的物理页。

```

early page table: 建立最大 8 GiB 可达窗口
    ↓
FDT `/memory/reg`: 发布本次启动的真实 RAM 末址
    ↓
frame allocator: 只管理 [kernel_end, physical_memory_end)
    ↓
kernel direct map 与 `/proc/meminfo`: 使用同一真实上限

```

图 4-2 RV64 可达范围与可分配范围的分离

图 4-2 中的两级边界还避免了 8 GiB 最大窗口被误当成可分配内存。为避免 direct map 本身消耗大量页表页，首个 RAM GiB 保留 4 KiB 映射，以继承内核各 section 的细粒度权限；后续完整 GiB 使用 Sv39 level-2 的 1 GiB 叶页。这一优化只影响页表成本，不改变上层的页帧和 VMA 模型。

4.4 VMA 变换与映射类型

RespOS 把 mmap、munmap、mprotect、mremap、MAP_FIXED 对地址空间的修改收敛在 MemorySet 中，因为这些操作共享同一组范围校验、VMA 切分和页帧转移规则。syscall 层只解析 Linux ABI 参数、用户指针、fd 和 errno，不再维护第二套地址空间状态机。

当操作只覆盖某个 VMA 的中间区间时，split_by_overlap 统一将原 VMA 分成左、中、右三段。切分不仅改虚拟范围，还同步分配 data_frames、修正 file backing 偏移和有效长度，并保留 shared、locked、wipe_on_fork、dontfork 等元数据。debug 启动时会运行头部、尾部、中段和二次切分自测，防止系统调用各自实现切分时出现语义漂移。

不同 VMA 的建图与派生策略汇总于表 4-3。

表 4-3 主要 VMA 类型及其建图策略

VMA 类型	建立时	首次访问	fork 后关系
私有匿名 mmap	只记录 VMA	分配清零页	已驻留可写页进入 COW，未驻留页各自缺页
brk 堆	RV64 记录 lazy VMA； LA64 当前预先驻留	按架构策略处理	私有可写页进入 COW
私有文件映射	记录 file/offset/len	分配私有页并按页读文件	已驻留可写页进入 COW，修改不回写原文件
共享匿名映射	预先建立共享页	直接访问共享 frame	父子保持共享，不进入 COW
共享文件映射	在 MM 锁外预取并按文件页身份复用 frame	直接访问共享 frame	父子保持共享，解除映射前进入写回协议
文件系统主 ELF 段	exec 只记录 PT_LOAD backing	按页读取文件，BSS 剩余部分保持为零	exec 前的派生遵循私有文件页规则

需要特别注意的是，当前 ELF loader 为用户栈创建的是已驻留映射，并在栈底下方保留守护页；因此，本章不将“用户栈懒分配”列为当前特性。不同映射类型的差异由 backing 和 shared 语义决定，而不是根据调用这些对象的系统调用路径临时推测。

4.5 缺页处理与按需分配

RespOS 将合法缺页视为延迟工作的统一入口。RV64 和 LA64 的异常编码不同，但架构 trap 层都将其归一为取指、读取和写入三类 PageFaultCause；公共内存层再由故障地址定位 VMA，并根据访问类型检查 R/W/X/U 权限。

用户态 page fault

↓
地址位于用户上界内，且存在匹配 VMA？

└ 否：返回 EFAULT，交由 trap/signal 路径处理

└ 是：VMA 权限允许本次取指/读/写？

└ 否：拒绝访问

└ 是

└ PTE 有效 + COW 写：恢复写权限或复制新页

└ PTE 缺失：分配匿名页或按页读取 file backing

└ PTE 已被其他 CPU 补好：本地 fence 后重试指令

图 4-3 handle_page_fault 决策流程

图 4-3 的最后一个分支是多核环境下的必要补充。页错误可能已被当前 CPU 锁存，但当它等待 MemorySet 写锁时，另一个 CPU 可能已完成映射。内存层会重新检查最终 VMA 和 PTE；如果权限已满足，则只刷新本地 TLB 并重试原指令，避免把一次已被其他 CPU 修复的缺页误判为越界。

用户指针访问复用同一套缺页语义。copy_from_user 和 copy_to_user 先使用检查加法、页对齐和用户上界的范围函数验证整段缓冲区，再确保每个 lazy/COW 页可访问，最后通过 PTE 对应物理页逐页复制。内核不直接构造用户 slice，因此既能处理跨页和跨相邻 VMA 的缓冲区，也不会因直接解引用一个尚未驻留的用户地址而在内核态再次缺页。

4.6 写时复制

COW 将 fork 的成本从“复制全部私有页”改为“只复制后续真正被写的页”。之所以这样设计，是因为许多子进程会很快调用 exec 或退出，在 fork 时立即复制全部驻留页往往不会产生用户可见的价值。

MemorySet::from_existed_user 处理三种情况：已驻留的私有可写页由父子共享同一 Arc<FrameTracker>，两个 PTE 都去掉 W 位并设置软件 COW 标志；私有只读页直接共享且保持只读；尚未驻留的 lazy 页只复制 VMA 元数据，父子以后分别缺页。shared VMA 则始终共享原 frame，不进入私有 COW 路径。

代码片段 4-3 COW 缺页的单所有者与多所有者分流

```
// os/src/mm/memory_set.rs (等价节选)
let old_frame = area.data_frames.get(&vpn).ok_or(Errno::EFAULT)?;
if Arc::strong_count(old_frame) == 1 {
    page_table.modify_pte(vpn, PTEFlags::from(area_perm));
    page_table.clear_pte_cow(vpn);
} else {
    let old_data = old_frame.ppn().get_bytes_array();
    area.remap_one_with_data(page_table, vpn, old_data)?;
}
```

如代码片段 4-3 所示，写缺页时如果当前进程已是页帧的唯一所有者，只需恢复 W 位；仍有其他所有者时，才申请新页、复制 4 KiB 数据并替换当前 PTE。新页在替换前已分配且填充完成，因而 ENOMEM 不会在原地址空间中留下空洞。

fork 建立 COW 时也遵循页粒度的先准备后提交：先把子进程 PTE 映射到共享页帧，成功后再将该页的父 PTE 改为 COW。若后续页处理失败，已转换的父页可能保留为只读 COW，但它仍然指向原数据并可在下次写入时正常恢复；这保证了失败路径不丢页、不丢数据，而不夸大为全地址空间一次性事务。

4.7 共享文件映射与锁外写回

可写 MAP_SHARED 的难点不是建立 PTE，而是同一文件页的多个映射如何看见同一份修改，以及 msync、munmap、MAP_FIXED、mremap、mprotect 和进程退出如何共用同一条写回协议。RespOS 以 (dev, ino, page_index) 作为共享文件页身份，用弱引用缓存复用存活的 FrameTracker，使同一文件页的不同映射共享物理内容。

写回使用“锁内快照、锁外 I/O、成功后改图”的协议。如图 4-4 所示，内存层持 MemorySet 锁时只校验范围并把驻留页内容复制到独立 FileWriteback 快照；锁释放后才经 FileOp 写入页缓存，MS_SYNC 再额外执行 fsync；对能向用户返回错误的映射 syscall，写回成功后才解除或替换映射。




图 4-4 共享文件页的锁外写回协议

之所以不在 MemorySet 锁内直接调用文件后端，是因为文件 I/O 可能获取页缓存、inode、ext4 和块设备锁，不仅会放大地址空间临界区，也会引入 MM—FS 锁序环。快照对象与 MemorySet 脱钩，使后端 I/O 的错误可以在修改映射前返回给 syscall，同时保持内存层和文件层的责任边界。进程退出没有可接收 errno 的调用方，因此退出路径会记录写回错误后继续释放地址空间，而不会因无法返回错误而泄漏进程资源。

当前实现没有利用硬件 dirty bit 做精确脏页追踪，因此会保守写回已驻留、可写的共享文件页。MS_INVALIDATE 需要 inode 级的全局失效协议，当前明确返回 EOPNOTSUPP；文件截断后访问已映射页的完整 SIGBUS 边界也尚未建立。这些限制界定了当前共享写回语义，不影响已实现的 MS_ASYNC 页缓存写入和 MS_SYNC 同步刷新路径。

4.8 大 ELF 按需装载

RespOS 对文件系统 ELF 采用 file-backed PT_LOAD 设计，因为“先把整个可执行文件读入内核 Vec，再为用户段分配物理页”会使内核堆同时承受整文件副本和 loader 中间对象。对 45,559,552 字节的 cargo 而言，仅临时文件副本就接近 RV64 64 MiB 内核堆的容量。

try_from_elf_file 只读取 ELF64 header、program header 和 PT_INTERP 名称，并将元数据前缀硬限制为 1 MiB。主程序的 PT_LOAD VMA 持有 Arc<dyn FileOp>、页对齐偏移和文件有效长度；首次访问才分配私有 frame 并按页读取，而新页未被文件覆盖的部分天然保持为零，满足 BSS 语义。

表 4-4 对比了整文件 eager loader 与当前 file-backed loader 的资源边界。

表 4-4 整文件装载与 file-backed ELF 对比

对比项	整文件 eager loader	当前 file-backed loader
exec 临时内存	随 ELF 文件大小增长	只保留有界元数据，上限 1 MiB
PT_LOAD 驻留	exec 阶段集中分配	首次访问时逐页分配
BSS 处理	loader 显式填充	页帧先清零，只覆盖文件有效字节
异常 ELF	可能放大内核分配	检查 header 尺寸、偏移、文件末尾和页内同余，失败返回 ENOEXEC

该路径已支撑上述 cargo 在 RV64 -smp 8 -m 8G 环境中运行到 BUILDSTORM_TOOLCHAIN ok。这一结果证明动态物理内存发现、大文件元数据有界读取和私有 file fault 已能共同支撑大型工具链启动。这不等于 BuildStorm 最终多核编译已通过；当前动态链接器仍使用整文件读取路径，后续可继续复用同一 file backing 抽象。

4.9 多核 TLB 可见性与生命周期

当 CLONE_VM 任务在多个 CPU 上共享同一 MemorySet 时，修改 PTE 后只执行本地 sfence.vma 是不够的，因为远端 hart 可能继续使用旧 TLB 项，甚至在页帧已被回收后仍访问原 PPN。RespOS 因此在 RV64 MemorySet 中维护真实 active_hart_mask：调度器在恢复任务前、持地址空间读锁发布当前 hart bit；只有当 CPU 已切回 per-CPU idle/kernel 页表后才清除。

页表修改者（持 MemorySet 写锁）

→ 更新 PTE

→ 顺序 fence + 本地 sfence.vma

→ active_hart_mask - current_hart

→ SBI remote SFENCE 到相关远端 hart

→ 当前 OpenSBI 等待远端 fence 完成后返回

→ 之后才能安全回收旧页帧

图 4-5 RV64 共享地址空间的定向 TLB shutdown

图 4-5 所示协议的优势是只向当前真正加载该地址空间的远端 hart 发送 RFENCE, 避免对所有 CPU 广播。它依赖当前 QEMU/OpenSBI 的同步 RFENCE 完成语义; 更换 firmware、绕过 SBI 或引入 ASID 后, 都必须重新审计 request/ack 与页帧回收顺序。LA64 当前不沿用这一 RV64 专用验收结论。

地址空间的退出同样遵循真实工作集。MapArea::unmap 对 Direct 映射遍历全范围, 对可能巨大而稀疏的 Framed VMA 只遍历 data_frames 中的驻留 VPN; 页表拥有的页帧则先进入架构后端的有限隔离队列, 避免退出路径仍短暂运行在旧页表时立即重用其页表页。这使回收复杂度与实际驻留内存而不是虚拟保留跨度成比例。

4.10 与其他模块的协作

内存管理不直接决定 syscall ABI、进程调度或文件持久化, 而是向这些模块提供可组合的地址空间协议。表 4-5 给出主要边界。

表 4-5 内存管理的跨模块接口

协作模块	内存层提供的能力	对方必须保证的条件
syscall	范围校验、VMA 建图/切分/改权限、用户 copy	只解析 ABI 和 errno, 不绕过 MemorySet 直接修改 PTE
task / scheduler	COW 派生、CLONE_VM 共享、地址空间激活/回收	exec/exit 回收前确保远端 sibling 不再使用旧地址空间
trap / arch	公共 handle_page_fault、页表操作与 TLB 刷新入口	将架构故障归一为 Instruction/Load/Store, 正确实现 PTE/COW 标志
VFS / page cache	file-backed VMA、共享文件页和写回快照	FileOp 提供按偏移读写、stat、fsync 和 mmap 生命周期回调
procfs / sysinfo	真实物理页帧数和内核堆统计	不把早期最大可达窗口当成真实 RAM

4.11 功能与设计成果总结

RespOS 内存管理的主线不是罗列更多分配算法, 而是在统一所有权模型上完成 Linux ABI、文件系统和多核的组合。表 4-6 总结已形成的设计成果及其证据边界。

表 4-6 内存管理成果与当前边界

方向	已实现的设计成果	当前证据或边界
地址空间	MemorySet—VMA—PTE—Frame 统一模型，范围修改共用切分逻辑	debug 不变量与 split self-test 直接检查 结构正确性
节省实际内存	私有匿名页、私有文件页和主 ELF 按需驻留；fork 使用 COW	无 swap 和通用页回收器；LA64 brk 当前为 eager
文件共享映射	共享 file frame + 锁外快照写回	2026-08-02 记录的 mmap/munmap 子集中，RV64 musl/glibc 各 20 通过、2 个已知边界失败；LA64 各 15 通过、0 失败；MS_INVALIDATE 和 truncate-SIGBUS 未完整实现
大程序装载	FDT 动态 RAM + file-backed 主 ELF + 1 MiB 元数据上限	2026-08-06 的 RV64 8 核/8 GiB 记录达到 BUILDSTORM_TOOLCHAIN ok；最终 minibuild/多核编译不由此结果代替
多核页表	RV64 active-hart 跟踪和定向 SBI RFENCE，旧 frame 回收前完成 shutdown	2026-08-06 的 2/8 核共享 MM 专项压力已通过；结论限于当前 QEMU/OpenSBI，LA64 SMP 待专项验证

在这套模型中，“分配一页内存”已经不只是分配器的局部操作。虚拟范围可以延迟承诺，但权限必须在 VMA 和 PTE 两层一致；物理页可以共享，但所有权和回收必须有唯一落点；写回和页表替换可以分阶段执行，但失败不能留下半完成状态。

5. 文件系统

本章介绍文件描述符、路径、目录项和 inode 之间的关系，并说明 ext4、procfs、devfs、页缓存和文件映射如何接入这套模型。

RespOS 的文件系统参考并实现了类 Linux 的 VFS 分层模型。这个模型把三个容易混淆的问题分开：文件在目录树中的位置是什么，文件本身具有什么属性和操作，某一次打开之后又处于什么状态。路径查找解决第一个问题，InodeOp 解决第二个问题，FileOp 解决第三个问题，FdTable 再把这些内核对象映射为用户态看到的整数 fd。

文件系统主要以 ext4 作为持久化后端，同时接入 procfs、devfs、tmpfile、pipe、socket 等对象。它们不需要都具有磁盘 inode 或路径，但只要实现相应的 FileOp，就可以复用 read、write、poll、fcntl 和 close 等文件描述符语义。文件后端 I/O 与地址空间管理则通过 FileOp 的按偏移访问和 mmap 写回接口连接起来。

5.1 VFS 对象模型

5.1.1 File：一次打开文件的运行时状态

文件系统对象进入用户态前，会经历“路径找到 inode、根据 inode 建立打开对象、把打开对象放入 fd 表”的过程。RespOS 中，普通文件的打开实例由 File 表示，并实现 FileOp trait。File 自身保存稳定的 inode 引用，动态变化的打开状态则集中放在受互斥锁保护的 FileInner 中：

```
pub struct File {
    inode: Arc<dyn InodeOp>,
    inner: Mutex<FileInner>,
}

struct FileInner {
    offset: usize,
    path: Arc<Path>,
    flags: OpenFlags,
    dirent_cache: Option<Arc<Vec<LinuxDirent64>>>,
    page_cache: Option<Arc<PageCache>>,
    write_back: bool,
    ...
}
```

代码片段 5-1 File 与 FileInner 的核心状态

FileInner 中的 offset 以字节为单位，表示该“打开文件的描述符”当前的访问位置；path 将这次打开与挂载实例中的 dentry 绑定；flags 保存打开状态；page_cache 和

write_back 则把普通文件的 I/O 与缓存写回连接起来。File 构造时会增加 ext4 inode 的打开计数，并根据 inode 类型取得共享页缓存。

打开标志会直接影响初始状态。若指定 O_TRUNC 且以写模式打开，构造阶段先将文件截断并同步调整缓存长度；若指定 O_APPEND，普通文件的初始 offset 设置为当前文件大小，否则从零开始。之后 read/write 在 FileInner 锁内推进 offset。因此两个独立的 open 创建的 File 拥有独立访问位置，而 dup 或 fork 复制同一个 Arc<dyn FileOp> 时会共享该位置。

5.1.2 FileOp：统一不同类型文件的使用方式

File 实现 FileOp，这个 trait 描述用户通过 fd 使用一个打开对象时需要的行为，而不是描述磁盘上的文件身份。普通文件、管道、标准输入输出、socket、epoll 和 memfd 都可以以 Arc<dyn FileOp> 进入 FdTable：

```
pub trait FileOp: Any + Send + Sync {
    fn read(&self, buf: &mut [u8]) -> SysResult<usize>;
    fn write(&self, buf: &[u8]) -> SysResult<usize>;
    fn read_at_offset(&self, offset: usize, buf: &mut [u8]) ->
SysResult<usize>;
    fn write_at_offset(&self, offset: usize, buf: &[u8]) -> SysResult<usize>;
    fn can_seek(&self) -> SysResult;
    fn seek(&self, offset: isize) -> SysResult<usize>;
    fn get_offset(&self) -> usize;
    fn set_status_flags(&self, flags: OpenFlags) -> SysResult;
    fn readable(&self) -> bool;
    fn writable(&self) -> bool;
    fn read_ready(&self) -> bool;
    fn write_ready(&self) -> bool;
    fn register_poll_waiter(&self, tid: usize, events: PollEvents) -> bool;
    fn fsync(&self) -> SysResult<usize>;
}
```

代码片段 5-2 FileOp 的核心操作接口

其中，read、write 和 seek 使用并更新打开实例的共享 offset；read_at_offset 和 write_at_offset 则提供不改变 offset 的无状态访问，供 pread、pwrite 和文件映射等路径使用。read_ready、write_ready 与 register_poll_waiter 表达阻塞和就绪语义：普通文件通常直接报告可读写，pipe 根据缓冲区和端点状态判断，socket 则根据协议缓冲区判断。不可 seek 的对象保留默认的 ESPIPE 行为，特殊文件可以覆盖相应操作。

FileOp 的意义在于抽象出了如何使用文件的接口，而不关注其存储形式。因此 pipe 和 socket 也可以通过同一接口接入 read、write、poll 和 close；普通文件则在 FileOp 实现内部继续调用 InodeOp、Path 和 PageCache。

5.1.3 InodeOp：文件对象的后端能力边界

InodeOp 解决的是对文件对象的解释和后端操作的关联。它不直接对应用户态 fd，而是提供节点类型、属性、按偏移 I/O、截断、目录查找、创建、链接、删除和可选的页缓存等能力：

```
pub trait InodeOp: Any + Send + Sync {
    fn as_any(&self) -> &dyn Any;
    fn node_type(&self) -> InodeType;
    fn stat(&self, path: &str) -> SysResult<KStat>;
    fn read_at(&self, path: &str, off: usize, buf: &mut [u8]) ->
    SysResult<usize>;
    fn write_at(&self, path: &str, off: usize, buf: &[u8]) -> SysResult<usize>;
    fn truncate(&self, path: &str, size: usize) -> SysResult<usize>;
    fn lookup(&self, parent_path: &str, name: &str)
    -> SysResult<Arc<dyn InodeOp>>;
    fn readdir(&self, path: &str) -> SysResult<Vec<LinuxDirent64>>;
    fn create(&self, parent_path: &str, name: &str, ty: InodeType)
    -> SysResult<Arc<dyn InodeOp>>;
    fn link(&self, old_path: &str, dentry: Arc<Dentry>) -> SysResult;
    fn unlink(&self, dentry: &Arc<Dentry>) -> SysResult;
}
```

代码片段 5-3 InodeOp 的后端能力接口

read_at 和 write_at 使用显式偏移，因而同一 inode 可以被多个打开实例访问而不会共享打开位置；lookup、create 和 unlink 则表达目录在命名空间中的操作能力。get_page_cache 默认返回 None，只有支持普通文件缓存的后端覆盖它；时间、权限和扩展属性接口在不适用的后端上返回明确错误或空结果，procfs、devfs 等对象不需要伪造磁盘文件语义。

当前接口中的 path 参数来自 lwext4 的路径型访问方式。VFS 通过 Path 和 Dentry::current_abs_path() 生成当前后端路径，再由具体 inode 实现把统一操作转换成底层调用。这个参数是当前 ext4 适配层需要的实现细节。

5.1.4 Ext4Inode: InodeOp 的具体实现

Ext4Inode 是 RespOS 对 ext4 普通文件和目录的 VFS 适配对象。它没有把 lwext4 的临时打开句柄直接暴露给上层，而是长期保存 inode 身份、路径变化和内核侧缓存状态；每次执行具体 I/O 时，再以当前有效路径创建短生命周期的 Ext4File 调用 lwext4：

```
pub struct Ext4Inode {
    pub ino: u64,
    ty: Ext4InodeTypes,
    times: Mutex<Option<InodeTimes>>,
    mode_override: Mutex<Option<u32>>,
    owner_override: Mutex<Option<(u32, u32)>>,
    nlink_override: Mutex<Option<u32>>,
    orphan_path: Mutex<Option<String>>,
    renamed_path: Mutex<Option<String>>,
    open_files: AtomicUsize,
    page_cache: Arc<PageCache>,
    xattrs: Mutex<HashMap<String, Vec<u8>>>,
}
```

代码片段 5-4 Ext4Inode 的核心状态

这些字段分别承担四类职责：ino 和 ty 标识后端对象；时间、权限、所有者和链接数覆盖字段保存 VFS 需要但当前后端不能直接稳定提供的元数据；orphan_path 与 renamed_path 处理路径变化期间仍然存活的 inode；open_files 区分真正的打开实例数量；page_cache 使同一个 inode 支持多个 File 共享文件数据缓存。

ext4 inode 的创建经过 inode cache：get_or_create 先按 inode 号查找全局缓存，已有 Arc<Ext4Inode> 仍被使用时，新的路径查找会复用同一 inode 对象，所有打开实例也就共享同一份页缓存和内核侧元数据。

具体操作需要同时处理 VFS 语义和 lwext4 的错误、锁与路径约束。lookup 通过 ext4 目录遍历获得子 inode 号和类型，再调用 get_or_create；read_at、write_at、stat 和 truncate 使用 storage_path 选择当前后端路径，创建临时 Ext4File 完成底层操作。对共享的 lwext4 入口，适配层使用 EXT4_OP_LOCK 串行化 FFI 调用，避免底层全局状态被并发破坏。

Ext4Inode 还承担普通 inode 生命周期中最难由单次路径调用解决的两类语义：

- **rename**。dentry 可以保持自身身份并更新父链，但 lwext4 后端需要访问新的路径。RespOS 将新路径记录到 renamed_path，使已经打开的 File 后续通过 storage_path 不再访问旧路径。
- **unlink 与延迟清理**。如果文件仍有打开者且链接数归零，适配层先把后端文件改名为 .respos_orphan_<ino>，将内核侧链接数覆盖为零；最后一个 File 关闭时，open_files 归零并删除这个隐藏路径。这样目录项可以先从命名空间消失，已有 fd 仍然可以继续访问文件内容。

因此，Ext4Inode 并不是简单的“lwext4 inode 指针包装”，而是 VFS 语义与路径型 ext4 后端之间的适配层：它统一缓存 inode 身份，维护打开计数和元数据覆盖，协调 rename/unlink 生命周期，并把普通文件读写接入共享页缓存。

5.1.5 Dentry、Path 与对象定位

Path 是 (VfsMount, Dentry) 二元组，表示一个对象在整个挂载命名空间中的位置；Dentry 维护名字、父目录、子目录缓存等：

```
pub struct DentryInner {
    pub inode: Option<Arc<dyn InodeOp>>,
    pub parent: Option<Arc<Dentry>>,
    pub children: HashMap<String, Weak<Dentry>>,
    alias_path: Option<String>,
}
```

代码片段 5-5 Dentry 的路径树状态

inode == None 表示负目录项，可缓存“该名字不存在”的结果。父节点使用强引用以支持沿父链重建路径，子节点使用 Weak 避免形成永久引用环。rename 时 dentry 保持

对象身份，通过父链和 alias_path 计算新的后端路径；unlink 删除名字空间中的 dentry 连接，但不必立即销毁仍被打开的 inode。

5.2 挂载树与路径解析

5.2.1 VfsMount 与 Mount

RespOS 将“一个文件系统实例”和“它挂载到哪里”分开表示。VfsMount 保存该实例的根 dentry、超级块和挂载 flags；Mount 保存挂载点、父挂载和子挂载，形成全局 mount tree：

```
pub struct VfsMount {
    pub root: Arc<Dentry>,
    pub fs: Arc<dyn SuperBlockOp>,
    flags: AtomicI32,
}

pub struct Mount {
    pub mountpoint: Arc<Dentry>,
    pub vfs_mount: Arc<VfsMount>,
    pub parent: Option<Weak<Mount>>,
    pub children: Mutex<Vec<Arc<Mount>>>,
}
```

代码片段 5-6 文件系统实例与挂载树节点

路径解析遇到挂载点时，会把游标中的 mnt 和 dentry 一起切换到子文件系统根目录。反向解析 .. 时，如果当前 dentry 已经是子文件系统根，则沿 Mount.parent 返回父文件系统中的挂载点。这样，路径语义既能在每个文件系统内部保持独立，又能在全局命名空间中正确跨越挂载边界。

当前初始化流程把 ext4 根文件系统作为主存储后端，再将 procfs 和 devfs 以独立的 VfsMount 挂载到 /proc 和 /dev。tmpfs/shm 等接口也通过 VFS 和特殊文件对象提供相应语义。

5.2.2 namei 路径遍历

路径查找由 Nameidata 驱动。它保存当前挂载实例、当前 dentry、待处理的路径分量和遍历深度。相对路径从当前工作目录或 dirfd 对应的目录开始，绝对路径从任务 root 开始；dirfd、空路径、符号链接跟随等路径操作选项由 syscall 层传入并在 namei 中解释。

一次典型的 link_path_walk 过程如下：

```
校验 PATH_MAX / NAME_MAX 和 dirfd
|
▼
确定起点：root、cwd 或 dirfd 对应目录
|
▼
逐分量查找 dentry cache
├─ 命中：检查挂载穿越并继续
```




图 5-2 namei 路径解析流程

符号链接展开采用重新组织剩余路径的迭代流程，并限制最多跟随 40 次，避免深层链接造成无限循环或内核栈增长。对 create、unlink、rename、link 和 symlink 等修改命名空间的操作，当前实现使用 NAMEI_MUTATION_LOCK 串行化关键路径，以简化 dentry cache、后端路径和失败回滚之间的一致性维护。

路径修改、后端操作和 dentry 缓存维护因此处于同一条可控的更新路径，create、unlink 和 rename 的可观察结果更容易保持一致。这也是当前适配路径型 lwext4 接口时的取舍：先保证命名空间状态和失败回滚，再根据实际并发负载细化锁粒度。

5.3 ext4 与虚拟文件系统后端

5.3.1 ext4 适配层

RespOS 通过 lwext4_rust 的 FFI 接入 ext4，Ext4Inode 负责把 InodeOp 的统一语义翻译为 lwext4 的路径型接口。VFS 层不直接操作 lwext4 的临时文件句柄，而是由 inode 根据当前 storage_path 创建短生命周期的 Ext4File，完成读写、属性查询、目录遍历和命名空间修改；底层错误再由适配层转换为 Linux 风格 errno。

这一适配层还补齐了 lwext4 不直接替 VFS 管理的语义：open_files 单独记录 File 数量；普通 ext4 inode 通过 get_page_cache 接入共享页缓存；rename 后通过 renamed_path 保证旧的打开对象继续访问正确的后端路径；unlink 后通过 orphan 路径延迟清理，使名字从目录树中消失后，已有 fd 仍能继续访问文件。

5.3.2 procfs、devfs 与特殊文件

procfs 和 devfs 都实现 SuperBlockOp，并通过独立挂载实例提供自己的根 inode。它们的 inode 通常动态生成内容，而不是从 ext4 数据块读取。例如 /proc/cpuinfo、/proc/meminfo、/proc/self/maps 等文件在 read 时根据内核状态生成文本；/dev/null、/dev/zero、/dev/random、tty、shm 等设备则由各自的 FileOp 或 InodeOp 实现读写语义。

pipe 不依赖磁盘 inode。两个端点共享一个带有读写关闭状态、FIFO 等待队列和 poll waiter 的环形缓冲区；当没有读者或写者时，端点生命周期决定 EOF 和 SIGPIPE 等可观察行为。socket、eventfd、epoll、timerfd 等对象也直接以 FileOp 形式进入 FdTable。这些对象复用文件描述符、poll 和 close 机制，但不套入 ext4 的页缓存或路径生命周期。

5.4 页缓存与持久化写回

5.4.1 PageCache 的职责

PageCache 以页为单位缓存普通文件内容，并维护缓存长度、页内容、脏状态和写回版本等信息。File 构造时从 inode 获取共享页缓存；顺序读、指定偏移读和普通写都优先通过 PageCache 完成。首次读取尚未驻留的区间时，缓存向后端发起按偏移读取；写入则先修改缓存页，再根据同步标志或显式同步请求执行写回。

页缓存把用户可见的文件长度和后端磁盘长度分开管理：写入扩大缓存后，stat 可以观察到新的长度，真正的后端更新由写回链路提交。O_SYNC、O_DSYNC 和 fsync 会提高写回强度；普通 close 路径也会尝试刷新自身的脏页，最后一个 ext4 打开对象关闭时还会触发孤儿文件清理。

5.4.2 三层写回链

当前普通文件的持久化路径可以概括为：




图 5-3 文件写入与持久化写回链路

File::fsync 会先刷新关联页缓存，再调用当前路径所属 VfsMount 的超级块同步操作。对普通 ext4 文件，缓存写回和后端同步是两个层次：前者把内存中的脏页交给 inode 后端，后者推动文件系统和设备完成更底层的提交。不能只调用其中一层就宣称数据已经持久化。

5.4.3 与 mmap(MAP_SHARED) 的协作

文件映射的写回由 MM 和 FS 共同完成。建立可写共享映射前，FileOp::mmap_allowed 检查文件是否可读，并要求 MAP_SHARED|PROT_WRITE 对应的“打开文件的描述符”可写。映射建立后，页面内容由地址空间管理；在 msync、munmap、MAP_FIXED 替换、mremap 收缩/覆盖、mprotect 或进程退出等路径中，MM 在地址空间锁内取得已有页帧的快照，然后释放 MemorySet 锁，再通过 FileOp 写入页缓存或后端，最后按需要调用 fsync。

这种“快照—锁外 I/O—同步”的协议有两个目的：避免文件后端 I/O 持有地址空间写锁导致锁序反转，也避免后端阻塞把所有地址空间操作串在一起。由于当前硬件路径没有统

一提供 dirty bit，系统对已有可写共享页帧采用保守写回，从而以更明确的同步行为换取实现可靠性。

5.5 文件描述符表与生命周期

5.5.1 FdTable 与 FdEntry

FdTable 是进程持有的描述符槽位集合，内部使用自旋锁保护槽位数组，并维护下一个分配位置及 RLIMIT_NOFILE 限制。每个槽位保存一个 FdEntry：

```
pub struct FdEntry {
    pub file: Arc<dyn FileOp>,
    pub flags: OpenFlags,
}
```

代码片段 5-7 描述符槽位与打开对象的关系

FdEntry::flags 保存每个描述符独有的标志，当前最重要的是 close-on-exec。file 指向共享的 FileOp，其内部保存 offset、追加写和非阻塞等 open-file 状态。关闭描述符时，先从表中移除槽位，再由 Arc 引用计数决定何时释放 FileOp；普通 File 的析构会尝试同步页缓存，并减少 ext4 inode 的打开计数。

5.5.2 dup、fork、exec 与 close

- dup 和 fork 复制 Arc<dyn FileOp>，因此共享文件偏移和打开状态，但为新描述符创建独立的 FdEntry，可以单独设置 close-on-exec。
- exec 根据每个 FdEntry 的 close-on-exec 状态关闭描述符；共享的 FileOp 只有在没有其他引用时才析构。
- close 从 FdTable 移除槽位后，pipe、socket、特殊 fd 和普通文件分别执行自己的最后引用清理；pipe 的最后一个写端关闭才会让读端观察到 EOF，最后一个读端关闭则影响写端错误和阻塞唤醒。
- fcntl 修改描述符标志和打开状态时必须区分上述两个对象，不能把 close-on-exec 写入 File 的共享状态。

5.6 功能与设计总结

文件系统是连接了系统调用、进程、内存和设备的基础设施。表 5-2 总结了 RespOS 已形成的主要功能和对应设计。

功能或设计	主要实现	--- --- ---	VFS 对象抽象	通过 Path、Dentry、InodeOp、FileOp 和 SuperBlockOp 分离路径、命名、文件对象、打开状态与后端存储		磁盘文件系统	通过 lwext4_rust 接入 ext4，支持普通文件、目录、符号链接、硬链接、rename、unlink 和属性操作		虚拟文件系统	以独立挂载实例接入 procfs、devfs，并提供 /proc、/dev、shm 等内核和设备接口		路径与挂载	支持 cwd/root/dirfd 起点、dentry cache、
-------	------	-----------------	----------	---	--	--------	---	--	--------	--	--	-------	------------------------------------

符号链接、./.. 以及跨挂载点路径遍历 || 文件访问性能 | 通过 ext4 inode 级共享页缓存、目录项缓存和目录读取缓存减少后端访问 || 数据一致性 | 通过页缓存写回、fsync、unlink 孤儿文件和 rename 回滚维护文件数据与命名空间的一致性 || 内核模块协作 | 通过 file-backed VMA、mmap 写回、pipe、socket、poll 和统一 fd 生命周期连接 MM、task、IPC、network 与 drivers |

表 5-2 文件系统主要功能与设计对应关系

在一次普通文件访问中，fd 先定位到打开对象，打开对象持有路径，路径连接挂载实例和 dentry，dentry 再通过 InodeOp 调用具体文件系统。沿着这条调用链，系统同时支持磁盘文件、虚拟文件、设备文件和无路径特殊文件，缓存、同步、内存映射和进程生命周期也都能接入文件对象模型。

这套分层保留了 Linux VFS 模型的主要语义，也利用 Rust 的 Arc、trait 和错误传播机制管理对象生命周期、后端替换和失败路径。

6. 进程间通信与信号

本章介绍信号、管道、futex 和 System V 共享内存四种机制，以及它们与任务阻塞和唤醒的关系。

6.1 概述与机制分工

RespOS 没有把进程间通信实现为单一总线，而是按通信语义选择不同机制：信号传递离散异步事件，管道传递有序字节流，futex 只在竞争发生时进入内核，System V 共享内存让多个地址空间直接映射同一组物理页。四者最终都与任务调度器协作，因此“如何登记等待者、由谁完成事件、何时唤醒任务”是本章共同的正确性主线。

表 6-1 对比了四种机制的对象身份、阻塞条件和典型用途。它们并非相互替代，而是分别覆盖通知、传输、同步和大块共享四类需求。

表 6-1 RespOS IPC 与信号机制分工

机制	内核中的核心对象	是否传输数据	何时进入阻塞	典型用途
信号	每 线 程 SigPending、线 程 组 共 享 SigHandler	SigInfo 与信号编 号	sigsuspend、 sigtimedwait 或打断其他可中断 等待	异步通知、timer、 异常、子进程状态 变化
管道	共享 PipeRingBuffer 与读写端 FileOp	有序字节流	读空且仍有写端； 写满且仍有读端	shell 重定向、父子 进程输出捕获
futex	FutexKey、哈希 等待队列、完成状 态	用户数据留在共享 内存，内核只管理 等待关系	用户值等于期望值 且发生竞争	pthread mutex/ condvar、线 程 join
System V shm	ShmSegment、 共享 frame、每次 attach 记录	进程直接读写同一 物理页	映射本身不阻塞	大块共享数据、跨 进程共享状态

6.2 信号机制

6.2.1 线程状态与进程共享状态

RespOS 将信号状态分为线程私有和线程组共享两层。每个线程独立持有 pending 位图、mask、每个信号号对应的一份 SigInfo 以及备用信号栈；同一线程组共享 handler 表。这

一划分使 sigprocmask、sigsuspend 和 sigaltstack 保持线程语义，同时保证任一线程调用 sigaction 后，整个进程看到一致的处理规则。

代码片段 6-1 给出了 pending 状态的当前表示。位图负责快速查找最小的可投递信号，BTreeMap 保存与该信号号关联的信息；同一个信号号再次到达会覆盖 info 并保持一个 pending 位，因此当前语义不是 Linux 实时信号的逐项排队模型。

代码片段 6-1 每线程信号挂起状态

```
// os/src/signal/sig_struct.rs
pub struct SigPending {
    pub pending: SigSet,
    pub mask: SigSet,
    pub info: BTreeMap<i32, SigInfo>,
}
```

表 6-2 进一步说明了各对象的创建、共享和释放边界。exec 会清空 pending、重置备用栈，并将用户自定义 handler 恢复为默认动作；显式设为忽略的 handler 保持忽略，这与“新映像不继承旧用户函数地址，但保留忽略选择”的语义相符。

表 6-2 信号对象的生命周期与可见范围

状态	共享范围	主要更新者	生命周期边界
pending + SigInfo	每线程	kill/tkill/tgkill、异常、timer、pipe、子进程事件	投递或 sigtimedwait 消费；exec 清空
signal mask	每线程	sigprocmask、sigsuspend、handler 进入与 sigreturn	clone 继承当前 mask；sigreturn 恢复旧 mask
alt stack	每线程	sigaltstack	新线程使用默认值；exec 重置
handler 表	线程组共享	sigaction、SA_RESETHAND、exec	同组线程共同可见；exec 重置用户 handler

6.2.2 从产生到 sigreturn 的完整链路

信号来源包括 kill/tkill/tgkill、用户缺页或非法访问、timer 到期、向无读端管道写入以及子进程停止/继续/退出。线程级信号直接进入指定 tid；进程级信号在目标线程组中选择一个当前未屏蔽该信号的线程，若暂时没有成员可立即接收，则回退到 leader 或组内成员保存 pending。kill 还按 uid/euid/suid 检查发送权限，tgkill 同时校验 tid 是否属于指定 tgid。

如图 6-1 所示，内核并不在任意指令位置直接跳入用户 handler，而是在 trap 返回用户态前统一调用 handle_signal()。这时完整寄存器现场已经位于任务内核栈，内核可以在用户普通栈或备用栈上构造 signal frame，再通过修改 trap context 改写返回 PC、SP 和参数寄存器。

图 6-1 信号产生、挂起、投递与返回流程



普通 handler 使用 SigFrame 保存 SigContext 和旧 mask；设置 SA_SIGINFO 时使用 SigRTFrame，并向 handler 传入 siginfo_t 与 ucontext。SA_ONSTACK 选择备用栈，SA_NODEFER 决定 handler 执行期间是否自动屏蔽当前信号，SA_RESETHAND 在首次投递后恢复默认动作。所有 frame 都通过受检用户拷贝写入；构造失败时不会带着半成品现场返回用户态，而是按致命信号终止当前任务。

默认动作按表 6-3 分为四类。Core 类当前与 Term 一样终止线程组，但不会生成 core 文件；Stop 和 Continue 会记录 wait event 并向父进程发送 SIGCHLD，使 wait4(WUNTRACED/WCONTINUED) 能观察到状态变化。

表 6-3 默认信号动作与当前行为

动作类别	代表信号	RespOS 行为
Ignore	SIGCHLD、SIGURG、SIGWINCH	消费后不改变任务状态
Stop	SIGSTOP、SIGTSTP、SIGTTIN、SIGTTOU	任务进入 Stopped，父进程可等待该事件
Continue	SIGCONT	将 stopped 任务重新发布为 Ready，并记录 continued 事件
Term / Core	SIGTERM、SIGKILL / SIGSEGV、SIGABRT 等	进入线程组退出；Core 类暂不写 core 文件

6.2.3 可中断等待与架构安全约束

信号投递与调度器之间采用“pending + 可中断标志 + 具体等待队列清理”的协作方式。目标线程进入 futex、pipe、wait4 或 signal wait 前先设置 interruptible；投递者发现存在未屏蔽且非忽略信号后，将完成状态改为 Interrupted，从 futex 等专用队列移除 waiter，并尝试从 scheduler 的 blocked 集合唤醒 tid。等待者恢复后返回 EINTR，而不是继续无期限睡眠。

这里的关键不是多调用一次 wakeup_task()，而是让 wake、timeout、signal 和 exit 只能有一个完成者。否则同一 tid 可能重复进入 ready queue，或者一条路径删除了另一条

路径仍要使用的 waiter。futex 将这一规则显式编码为完成状态；pipe 和 wait 则通过“锁内登记 + 发布 blocked 后复查 + 恢复时清理残留”关闭竞态窗口。

RV64 的 signal return 还遵守统一的 trap 安全顺序：写回 sstatus 前清除 SIE，保持 kernel trap vector 直到通用寄存器和 per-CPU sscratch 恢复完成，最后才切换 user vector 并执行 sret。signal frame 来自用户地址空间，不能信任其中保存的中断使能位；这一约束同时保护普通 syscall 返回、handler 首次进入和 sigreturn。

当前 SA_RESTART 只完成 flag 解析，尚未实现系统调用自动重启，被信号打断的可中断系统调用通常返回 EINTR。pending 又按信号号合并，因此同一种实时信号连续到达时只保留一个 pending 位和一份 SigInfo。这两个边界明确限定了当前信号兼容层的范围。

6.3 管道：字节流、阻塞与端点生命周期

6.3.1 核心对象

匿名管道由两个 Pipe 端点共享一个 PipeRingBuffer。每个端点实现 FileOp，读端只允许 read，写端只允许 write；pipe2 将两个端点分别安装进 fd table，并在第二个 fd 分配或最终 copyout 失败时回滚已经分配的描述符。代码片段 6-2 展示了缓冲区中与同步直接相关的状态。

代码片段 6-2 管道环形缓冲区与等待队列

```
// os/src/fs/pipe.rs
struct PipeRingBuffer {
    buffer: VecDeque<u8>,
    capacity: usize,
    read_closed: bool,
    write_closed: bool,
    read_waiters: VecDeque<usize>,
    write_waiters: VecDeque<usize>,
    poll_waiters: Arc<PollWaiters>,
}
```

缓冲区默认容量在 RV64 与 LA64 上均为 64 KiB，并可通过受限接口按页调整。read/write waiter 保存 tid，poll waiter 则独立保存关注的事件掩码：前者负责把真正阻塞的任务移回 ready queue，后者负责通知 poll/epoll 重新检查文件状态。

6.3.2 读写阻塞协议

表 6-4 给出了读写端在不同缓冲区和端点状态下的行为。阻塞 read/write 都是可中断等待，信号到达后返回 EINTR；O_NONBLOCK 则在无法立即推进且尚未传输数据时返回 EAGAIN。

表 6-4 管道读写状态机

操作与条件	返回或状态变化	唤醒对象
read 且缓冲区非空	取出可用字节并返回	唤醒一个 writer, 通知 POLL_WRITE
read、缓冲区空、仍有写端	reader 登记并进入 Blocked	等待 write、写端关闭或 signal
read、缓冲区空、所有写端关闭	返回 0 (EOF)	poll 可观察 HUP/可读结束状态
write 且有空间、仍有读端	写入可容纳字节并返回	唤醒一个 reader, 通知 POLL_READ
write、缓冲区满、仍有读端	writer 登记并进入 Blocked	等待读取、读端关闭或 signal
write 且所有读端关闭	返回 EPIPE, sys_write 产生 SIGPIPE	当前任务按信号规则处理

管道把“检查条件、登记 waiter、发布 blocked”放在同一把 buffer 锁保护的区间内，如图 6-2 所示。写端必须取得同一把锁才能写入并取出 reader tid，因此不会在 reader 检查完空缓冲区、尚未登记时丢掉唤醒。若 waker 在 reader 真正 switch_to_next_task() 前已经把它改为 Ready，reader 会撤销 ready 入队并继续当前上下文，避免不必要的切换。

图 6-2 管道读空时的无丢失唤醒协议

```
reader (持 buffer 锁)
  检查为空且 write_closed = false
  ↳ read_waiters.push(tid)
  ↳ prepare_current_task_blocked()
  ↳ 释放 buffer 锁

writer (取得同一 buffer 锁)
  写入数据 → pop_read_waiter() → wakeup_task(tid)

reader 切换前复查:
  已经 Ready → 撤销队列项并继续
  仍为 Blocked → switch_to_next_task()
```

6.3.3 EOF、EPIPE 与 poll 可见性

匿名管道没有单独维护“fd 数量计数器”，其端点生命周期由 Arc<dyn FileOp> 管理。dup 或 fork 让多个 FdEntry 共享同一个端点对象，只有最后一个写端引用释放时，Pipe::drop() 才设置 write_closed 并唤醒全部 reader；最后一个读端释放时同理设置 read_closed 并唤醒 writer。因此 EOF 的条件是“缓冲区已空且最后一个写端对象已释放”，而不是“某个子进程已经 exit”或“当前暂时没有数据”。

这一语义与 fd table 生命周期直接相关。exec 必须先解除 CLONE_FILES 共享再执行 CLOEXEC，退出任务又要在安全时机释放遗留 fd 引用，否则捕获 stdout/stderr 的父进程会一直等不到 EOF。RespOS 的 unshare_fd_table_for_exec() 与 idle loop 的 cleanup_dead_tasks() 正是为这一跨模块引用链提供收敛点。

read_ready() 在“缓冲区非空或写端已关闭”时成立；write_ready() 当前要求至少有一页（或容量本身，若更小）的可写空间，而不是仅检查“未满”。端点关闭会通知 POLL_READ | POLL_WRITE | POLL_HUP, poll/epoll 随后重新读取实际状态。这使管道的阻塞、非阻塞和事件监控共享同一组状态来源。

6.4 Futex：用户态快路径与内核竞争路径

6.4.1 等待对象与 key

futex 的常见无竞争路径完全在用户态完成，只有用户值表明需要等待时才进入内核。RespOS 使用 256 个哈希桶保存 FutexQ，每个条目包含 FutexKey、等待 tid 和 bitset。key 必须表达“哪些地址实际上代表同一个同步字”，而不能只比较进程内虚拟地址。

表 6-5 给出了当前 key 生成规则。私有 futex 以 tgid 隔离同一虚拟地址；能识别的共享映射则转化为 backing 身份、页索引和页内偏移，使不同进程中的不同虚拟地址仍可落到同一等待队列。

表 6-5 FutexKey 的身份规则

映射类型	scope 来源	key 中的地址部分	目的或边界
FUTEX_PRIVATE_FLAG	tgid	原用户虚拟地址	仅同一线程组内匹配
共享文件映射	文件 dev/ino 派生身份	文件页索引 + 页内偏移	不同进程映射同一文件位置可互相唤醒
已有共享匿名 frame	物理 frame 身份	VMA 页索引 + 页内偏移	fork 继承或共享 frame 映射可匹配
System V shm	当前 attach id	attach 内页索引 + 页内偏移	同一次 attach 内稳定；不同进程独立 shmat 尚不能保证相同
无法解析为共享 backing	tgid	原用户虚拟地址	安全回退为进程内匹配

6.4.2 single-winner 完成协议

一次 futex wait 可能被 wake、deadline、signal 或任务退出结束。代码片段 6-3 中的完成状态把竞争结果显式记录在每个 tid 的 FutexWait 中；状态只能从 Pending 成功改变一次，后到事件发现已经完成后不再重复唤醒。

代码片段 6-3 futex 等待完成状态

```
// os/src/task/futex/wait.rs
enum WaitCompletion {
    Pending,
    Woken,
    TimedOut,
    Interrupted,
```



```
}

struct FutexWait {
    deadline: Option<FutexDeadline>,
    completion: WaitCompletion,
}
```

表 6-6 展示了每个完成者的提交动作。队列记录、完成记录和 deadline 索引都要同步清理；退出路径虽然不再返回用户态，仍必须删除三处状态，防止悬空 tid 被后续 wake 命中。

表 6-6 futex wait 的竞争完成者

完成者	目标状态	队列与调度动作	用户态结果
FUTEX_WAKE / WAKE_BITSET	Woken	从哈希桶移除并唤醒 tid	返回 0
deadline	TimedOut	删除 queue/deadline 记录并唤醒	ETIMEDOUT
signal	Interrupted	删除 futex waiter，由 signal 路径唤醒 scheduler	EINTR
task exit	不再恢复	清理 queue、wait、deadline 三处记录	无返回

6.4.3 requeue 的线性化与当前边界

FUTEX_CMP_REQUEUE 要求“比较源 futex 值”和“唤醒/迁移 waiter”属于同一个线性化区间。如果比较发生在队列锁外，另一个线程可能在比较后修改用户值，而内核仍按旧条件迁移 waiter。RespOS 先在锁外调用 check_user_readable() 解析 lazy 页，再在 FUTEX_QUEUES 锁内用固定 4 字节的 read_user_u32_nofault() 复核，随后完成 wake/requeue。这样既把比较与队列修改放在同一临界区，又避免持有 no-IRQ 自旋锁时触发补页或分配。

普通和定时 FUTEX_WAIT 的最终值复核目前仍在持有 FUTEX_QUEUES 时调用通用 copy_from_user(), lazy/COW 页可能进入补页路径；这一点尚未完全收敛到 cmp-requeue 的“锁外预触页、锁内 no-fault 读取”模式。另一个边界来自表 6-5：两个进程分别 shmat 同一个 System V 段时会得到不同 attach id，因此共享段上的跨进程 futex 还缺少稳定的 segment/frame 级身份。

6.5 System V 共享内存

6.5.1 段对象与映射生命周期

System V 共享内存由全局 SHM_TABLE 管理。ShmSegment 保存 key、权限、创建者/最后操作者、时间戳、删除/锁定状态以及一组 Arc<FrameTracker>; 每次 shmat 还

分配 attach id, 将同一组 frame 映射进调用者的 MemorySet。这里需要区分两种身份: segment/frame 是共享对象, attach 则表示某个地址空间中的一次映射关系。

图 6-3 展示了段从创建到删除的完整生命周期。IPC_RMID 在仍有 attach 时只设置 marked_removed, 使新查找不再获得该段; 最后一个 attach 消失后才从全局表删除并释放 frames, 符合“删除名字不立即破坏现有映射”的延迟删除语义。

图 6-3 System V 共享内存生命周期




表 6-7 总结了各系统调用的对象变化。SHM_RDONLY、SHM_EXEC、SHM_RND 和 SHM_REMAP 会影响映射权限或位置, shmctl 还提供 IPC_STAT/SET、SHM_STAT/INFO 及 LOCK/UNLOCK 的受限状态管理。


表 6-7 System V 共享内存操作与状态变化

操作	主要检查	成功后的状态变化
shmget	key/IPC_CREAT/EXCL、大小、权限、全局页数与段数上限	创建或返回 ShmSegment, 新段一次性分配所需 frames
shmat	shmid、访问权限、地址对齐与已知 flag	在当前 MemorySet 映射共享 frames, 登记 attach owner, 更新 atime/lpid
shmdt	地址对齐且属于某个 shm attach	删除该 attach, 更新 dtime/lpid, 必要时完成延迟删除
shmctl(IPC_RMID)	owner 或特权权限	无 attach 时删除; 否则标记 SHM_DEST
shmctl(SHM_LOCK/UNLOCK)	owner 或特权权限	记录 locked 状态和 ctime

6.5.2 shmat 的失败原子性

shmat 同时修改全局段表和进程地址空间, 任一阶段失败都不能留下“统计显示已 attach、页表却没有映射”的半成品。RespOS 先在 SHM_TABLE 中校验权限、复制 frame 引用并预留 attach id, 然后调用 MemorySet::mmap_area() 建图; 映射失败会删除 attach_owners[attach_id], 只有映射成功后才更新 segment 的 atime 与 lpid。图 6-4 给出了这一 prepare/commit 顺序。

图 6-4 shmat 的 prepare/commit 协议



当前实现不支持 System V 消息队列和 semaphore, SHM_HUGETLB 明确返回错误。系统也没有 swap, 因此 SHM_LOCK/SHM_UNLOCK 主要维护 ABI 可见状态, 不能解释为完整的换页锁定机制。这些边界不会削弱共享 frame 与延迟删除的主体语义, 但限制了 System V IPC 的实现子集。

6.6 跨模块协作与功能总结

四种机制最终通过 TCB、fd table 和 MemorySet 汇合。表 6-8 总结了本章的关键设计成果及其依赖关系。

表 6-8 IPC/信号机制的跨模块协作

机制	依赖的内核边界	已形成的能力
信号	TCB 的线程组/可中断状态、trap context、scheduler wakeup	异步产生、线程选择、handler frame、默认动作与 sigreturn 完整闭环
管道	FdTable/FileOp 引用生命周期、blocked/ready 调度、poll waiters	阻塞与非阻塞字节流、EOF/EPIPE/SIGPIPE、poll/epoll 通知
futex	MemorySet backing 身份、哈希等待队列、timer 与 signal	wait/wake/bitset/requeue、超时和 signal 的 single-winner 竞争处理
System V shm	frame 所有权、VMA/PTE 建图、全局段表	shmget/shmat/shmdt/shmctl、共享物理页、失败回滚与延迟删除

这些机制虽然用途不同, 但都要经过任务的阻塞、唤醒和退出路径。信号处理异步事件, 管道传递字节流, futex 处理低开销同步, 共享内存直接提供数据共享; 对象身份、waiter 注册和最后引用释放则分别由各自模块维护。

7. 时钟模块

本章介绍两个架构的时钟来源、timer trap 和超时管理, 并说明 clock、sleep、interval timer、POSIX timer 与 timerfd 如何使用同一套时间接口。

时钟模块是内核中连接硬件、调度器和用户态时间接口的基础设施。它一方面读取架构相关的硬件计数器并设置下一次 timer interrupt, 另一方面把“经过了多少时间”转换为不同用途的时间: 用户可见的运行时间、超时和 deadline 使用的单调时间, 以及 CPU 时间记账使用的时间。nanosleep、futex、interval timer、POSIX timer 和 timerfd 都建立在这些统一的时间接口之上。

RespOS 将“读取时间”和“等待事件”分开处理: 读取时间只查询计数器并完成单位转换, 等待事件则登记 deadline、阻塞当前任务, 在时钟安全点检查到期对象并唤醒任务或投递信号。这种分工使不同用户态接口可以共享计时基础, 同时保持各自的可观察语义。

7.1 时间模型与核心数据

7.1.1 三种时间尺度

内核不会把所有时间需求都直接绑定到同一个频率。架构层分别提供三种逻辑时钟频率:

时间尺度	使用场景	设计目的
hardware clock	设置硬件中断、timeout 和 deadline	反映底层计时器的真实运行尺度
user clock	clock_gettime、文件时间和用户可见运行时间	提供稳定的用户态时间单位和精度
accounting clock	times、getrusage 等 CPU 时间记账	为资源统计保留独立的计时口径

表 7-1 RespOS 的时间尺度

在当前架构实现中, get_time() 读取硬件计数器, get_time_ms/us() 按 user clock 转换, get_timeout_ms/us() 按 hardware clock 转换, get_accounting_ms/us() 按 accounting clock 转换。这样, 超时判断不会因为用户可见时间的展示策略变化而改变, CPU 记账也不必与 wall-clock 语义混在一起。

7.1.2 TimeSpec 与 deadline

用户态时间接口统一使用 TimeSpec 表示秒和纳秒:

```
#[repr(C)]
pub struct TimeSpec {
    pub sec: isize,
    pub nsec: isize,
```

```

}

impl TimeSpec {
    pub fn is_valid_duration(&self) -> bool {
        self.sec >= 0 && self.nsec >= 0 && self.nsec < 1_000_000_000
    }

    pub fn checked_duration_us(&self) -> Option<usize> {
        if !self.is_valid_duration() {
            return None;
        }
        (self.sec as usize)
            .checked_mul(1_000_000)
            .and_then(|us| us.checked_add((self.nsec as usize).div_ceil(1000)))
    }
}

```

代码片段 7-1 时间值校验与单位转换

TimeSpec 的校验不仅检查秒和纳秒的范围, 还在转换时进行校验, 防止用户提供的超大时间值在内核中发生整数溢出。相对等待会被转换为 $\text{now} + \text{duration}$ 的绝对 deadline; 绝对等待则直接使用目标时刻。之后各类定时器只需要比较当前时钟和 deadline, 而不必重复解释用户态结构体。

7.2 时钟源与时钟中断

7.2.1 RISC-V 与 LoongArch 的时钟源


公共内核只依赖架构层导出的 `get_time`、频率转换和 `set_next_ti_trigger` 接口, 具体硬件操作收敛在两个架构目录中。

RISC-V64。 RISC-V 通过 `time` 计数器读取当前 tick, 并通过 SBI `set_timer` 设置下一次 supervisor 定时器中断。`set_next_ti_trigger` 按硬件频率和固定 tick 周期计算下一次触发点, 当前系统每秒设置 100 次基础时钟检查。

LoongArch64。 LoongArch 通过 `rdtime.d` 读取稳定计数器, 并使用架构相关的 timer CSR 和 `set_timer` 设置下一次触发。启动阶段会通过 `CPUCFG` 读取并记录平台计时频率, 用于校准和诊断。运行时使用内核配置提供的时钟频率, 避免公共代码依赖具体平台寄存器。

7.2.2 Timer trap 的职责

一次 timer trap 主要完成三件事: 重新设置下一次硬件触发、在安全点处理到期对象、请求当前任务被调度。其逻辑可以概括为图 7-1:






图 7-1 时钟中断到超时处理的调用链

在 RISC-V SMP 模式下，全局 timeout 工作由定时器服务 hart 负责。用户态进入定时器中断时可以直接处理；内核态定时器中断只有在该 hart 处于 per-CPU 空闲上下文、没有持有任务相关高层锁时才执行全局扫描，其余 CPU 只重新设置本地 tick。这样既保留了多核下每个 CPU 的本地时钟，又避免 timer 中断在任意 syscall 临界区重入 task、signal 或 timer registry。LoongArch 当前在定时器中断中直接完成统一的到期检查和抢占。

无论采用哪种架构路径，timer trap 都只负责把硬件事件转换为内核时间服务；具体的 sleep、signal 和 fd 语义仍由各自的模块维护。

7.3 超时管理与任务唤醒

7.3.1 deadline registry

RespOS 当前没有把所有定时器抽象成一个统一的时间轮或单一堆结构，而是根据使用者的语义分别维护 deadline registry：nanosleep 等等待项按时钟类别和 deadline 组织，POSIX timer 使用全局 timer 表，进程 interval timer 保存在任务控制块中，timerfd 则保留自己的周期和累计到期次数。各类对象保留自身状态，统一的 check_all_task_timers() 只负责在安全点触发检查。

```

pub fn check_all_task_timers() {
    check_futex_timeouts();
    check_nanosleep_timeouts();
    check_timerfd_expirations();
    check_active_itimers();
    check_posix_timers();
}
  
```

代码片段 7-2 统一的到期检查入口

检查函数通常先在 registry 内确定已经到期的对象，再在释放 registry 锁后执行唤醒或信号投递，避免在持有底层容器锁时进入调度器或信号系统。

7.3.2 nanosleep 与阻塞唤醒

nanosleep 的实现首先校验用户提供的 TimeSpec, 使用 timeout clock 计算相对 deadline, 然后将当前任务登记到 nanosleep wait registry 并进入可中断阻塞。任务被唤醒后会重新检查三种情况: deadline 是否已经到达、是否收到信号、是否仍需继续等待。




图 7-2 nanosleep 的登记、唤醒与返回流程

相对 nanosleep 使用 timeout clock, clock_nanosleep 还可以使用 CLOCK_REALTIME、CLOCK_MONOTONIC 和 CLOCK_BOOTTIME 的绝对 deadline。被信号打断时, 内核根据开始时间和请求时长计算剩余时间, 并在用户 copyout 成功后返回, 从而保证等待状态不会因为失败的用户地址而提前提交。

7.3.3 interval timer 与 POSIX timer

任务控制块为三类 interval timer 保存 deadline、interval 和对应 signal。timer 到期后, 内核使用原子比较交换更新下一次 deadline, 再向任务投递信号; 一次性 timer 清零 deadline, 周期 timer 则根据 interval 重新装载。

全局 ACTIVE_ITIMER_TASKS 记录拥有活动 timer 的任务, timer service 只扫描这些任务, 避免每次 tick 遍历所有进程。

POSIX timer 使用独立的全局表保存 timer id、owner、clock、signal、deadline 和 interval。timer_create 先准备对象并将 id copyout 到用户地址, 成功后才把对象发布到全局表; timer_settime 先读取并校验新值, 在 old value copyout 成功后再提交 deadline。进程组退出时, 按照 owner tgid 一次性移除该组创建的 timer, 避免 timer 残留后向已经复用的任务标识投递信号。

7.4 用户态时间接口

7.4.1 clock_gettime 与系统时间

用户态可以通过 clock_gettime 读取不同语义的时钟:

时钟	RespOS 中的含义	典型用途
CLOCK_REALTIME	monotonic time 加可调整的 realtime offset	日历时间、文件时间、绝对时间
CLOCK_MONOTONIC	持续增长的单调时间	timeout、相对等待和 deadline
CLOCK_MONOTONIC_RAW	原始单调时间口径	需要避免 realtime 调整的计时
CLOCK_BOOTTIME	当前运行期间持续增长的时间口径	睡眠与系统运行时间相关接口
CLOCK_REALTIME_COARSE / MONOTONIC_COARSE	对应时间量化到毫秒	低开销的粗粒度查询

表 7-2 用户可见时钟接口

CLOCK_REALTIME 的调整通过独立的 offset 完成，不修改 monotonic 基准。已经登记的 monotonic timeout 不会因为设置系统时间而倒退或突然提前；使用 realtime 的绝对 timer 则按照 realtime 语义计算当前 deadline。粗粒度时钟通过量化结果减少高精度转换开销。

7.4.2 timerfd：将时间转换为文件事件

timerfd 将定时器包装成 FileOp，使定时器可以与 poll/epoll 和普通文件描述符一起等待。每个 timerfd 保存 clock id、interval、deadline、已消费的 expiration count 和 poll waiter：

```
#[derive(Clone, Copy, Default)]
struct TimerFdState {
    interval_ms: usize,
    deadline_ms: usize,
    consumed: u64,
}
```

代码片段 7-3 timerfd 的核心状态

读取 timerfd 时，内核根据当前时钟计算已经发生的到期次数，并返回一个 u64 计数；周期 timer 即使用户态没有及时读取，也不会为每次到期创建独立事件，而是把多次到期合并为累计次数。非阻塞读取在没有 pending expiration 时返回 EAGAIN，阻塞读取则通过统一的 poll waiter 等待下一次通知。

timerfd 本身仍以文件描述符参与生命周期管理，关闭最后一个引用时由 Arc 回收对象。全局 timerfd registry 只保存弱引用，用于在 timer service 检查到期状态后通知可读等待者，不会因为 registry 而延长已经关闭的 timerfd 生命周期。

7.5 与其他模块的协作

时钟模块通过统一的当前时间和到期检查入口服务多个内核子系统：

协作模块	时钟模块提供的能力	产生的用户态效果
task / scheduler	timer interrupt、抢占时机、任务 timeout 唤醒	sleep、阻塞任务按 deadline 恢复执行
futex	timeout clock 和到期检查	FUTEX_WAIT 的超时返回
signal	interval/POSIX timer 到期事件	SIGALRM 等信号投递
FS / poll	timerfd 的可读通知	timerfd 与 poll/epoll 统一等待
syscall	clock、sleep、timer 的 ABI 转换	用户态读取时间和设置定时器
net	单调时间戳	TCP/UDP 协议栈的超时与时间推进

表 7-3 时钟模块与其他子系统的协作关系

在 RespOS 中，架构目录负责读取计数器和设置中断，公共内核使用统一的毫秒/微秒接口；等待对象通过 deadline registry 接入时钟安全点，sleep、futex、signal、timerfd 和网络协议仍保留各自的状态。这样既能复用计时基础，也不会把不同对象的到期语义混在一起。

8. 网络模块

本章介绍 smoltcp 与 Linux socket ABI 的连接方式，以及 TCP、UDP、UNIX 域 socket 和并发 listen/accept 的实现。

RespOS 采用“内核管理 ABI、对象生命周期和阻塞语义，smoltcp 管理 TCP/IP 协议状态机”的分层设计。这一边界使项目无需重新实现 TCP 重传、滑动窗口和报文解析，而能把工程重点放在用户态真正可见的部分：fd 身份、bind/connect/listen/accept、阻塞与信号中断、backlog 并发容量、poll/epoll 就绪性以及 close 时的句柄回收。

当前数据面明确聚焦于本地回环通信。内核已实现 IPv4 loopback 上的 TCP/UDP，并为 AF_INET6 的 ::1 提供回环 ABI 兼容，同时实现基于内存队列的 UNIX 域 socket。源码中没有将 virtio-net 设备接入 Interface，因此本章不将真实以太网收发或物理网卡列为已完成能力。

8.1 分层架构与责任边界

RespOS 从 syscall 到数据包共分为五层。如图 8-1 所示，syscall/net.rs 负责 Linux ABI 结构解析和用户拷贝，Socket 负责 fd/VFS 统一抽象，TcpSocket/UdpSocket 管理内核可见状态，smoltcp 管理协议细节，LoopbackDev 则完成纯软件收发。



图 8-1 RespOS 网络模块分层调用链

表 8-1 进一步明确各层拥有的状态，以及不应越界处理的内容。

表 8-1 网络各层的所有者与职责

层次	主要对象	负责的状态	不在该层处理的内容
syscall ABI	SockAddrIn/ SockAddrIn6/ SockAddrUn、 MsgHdr、MMsgHdr	参数长度、字节序、用户指针、fd 分配与 errno	TCP 状态转换、句柄回收
fd/VFS 抽象	Socket : FileOp	domain/kind、非阻塞状态、统一 read/write/readiness	TCP 报文和 UDP 队列算法
传输层适配	TcpSocket、 UdpSocket、 ListenTable	连接粗粒度状态、本地/对端地址、backlog、阻塞等待	拥塞控制、重传算法
协议栈	smoltcp SocketSet、 TCP/UDP socket	TCP/IP 协议状态机、收发缓冲、报文处理	Linux fd 和进程语义
设备	LoopbackDev	待接收数据包队列和可复用缓冲池	真实 NIC 中断、DMA 和 virtqueue

这样分层后，更换协议库或增加真实网卡时，应优先保持 Socket : FileOp 和 syscall ABI 层不变；而修改 accept 并发性时，则必须同时审计 ListenTable、smoltcp handle 和 fd 的唯一所有权。

8.2 Socket 对象与 fd 生命周期

RespOS 通过让 Socket 实现 FileOp 将套接字纳入统一 fd 模型。这使 read/write/close/fcntl/ppoll/epoll 无需在文件和 socket 之间维护两套描述符表；对用户态而言，socket fd 与普通 fd 遵循相同的分配、复制和关闭边界，但通过 ESPIPE 明确拒绝 seek。

代码片段 8-1 用户可见 socket 的协议分派

```
// os/src/net/socket.rs (节选)
enum SocketInner {
    Tcp(TcpSocket),
    Udp(UdpSocket),
    Unix(UnixSocket),
}

pub struct Socket {
    pub domain: SocketDomain,
    pub kind: SocketKind,
    inner: SocketInner,
    nonblock: AtomicBool,
    cloexec: AtomicBool,
    send_buf_size: AtomicU64,
    recv_buf_size: AtomicU64,
}
```

```
impl FileOp for Socket {
    fn read<'a>(&'a self, buf: &'a mut [u8]) -> SysResult<usize> { /* 按协议分派 */ }
    fn write<'a>(&'a self, buf: &'a [u8]) -> SysResult<usize> { /* 按协议分派 */ }
    fn read_ready(&self) -> bool { self.tcp_poll(true) }
    fn write_ready(&self) -> bool { self.tcp_poll(false) }
}
```

代码片段 8-1 中的 Socket 是 open-file description: dup 或 fork 后的 fd 可以共享同一 socket 对象和连接状态。SOCK_NONBLOCK 在创建时传入对象, 后续 fcntl 也经 FileOp::set_status_flags 更新相同状态。SOCK_CLOEXEC 进入 fd 旗标语义, 使 exec 能经统一 fd table 路径关闭描述符。

socket 对象的创建与用户 copyout 还遵循失败原子性。例如 socketpair 会先检查用户结果数组, 再依次分配两个 fd; 第二个 fd 分配或最终 copyout 失败时, 已分配的 fd 会被回收。accept4 创建新 socket 并分配 fd 后, 若写回对端地址失败, 也会关闭新 fd, 不向进程留下不可达的连接对象。

8.3 回环设备与协议轮询

RespOS 将回环通信实现为符合 smoltcp Device trait 的纯软件设备。LoopbackDev 不经过 virtqueue 或 MMIO: 发送 token 从缓冲池取出 Vec<u8>, smoltcp 填充报文后将其推入接收队列; 下一次 interface poll 再通过接收 token 取出同一缓冲。接收 token 销毁时将缓冲归还池中, 池最多保留 64 个缓冲, 避免高频回环报文不断重新分配堆对象。

```
smoltcp TxToken::consume
    → 从 pool 取缓冲/按需分配
    → 填充 IP + TCP/UDP 报文
    → 进入 LoopbackDev.queue
    → Interface::poll()
    → RxToken::consume
    → 投递到对端 smoltcp socket
    → RxToken drop, 缓冲返回 pool
```

图 8-2 回环设备的纯软件数据路径

图 8-2 中的全局 SocketSet、loopback Interface、LoopbackDev 和 ListenTable 均由锁保护。poll_interfaces() 以当前内核时间驱动 Interface::poll(), 使 smoltcp 处理新报文、TCP 状态转换和缓冲投递; 随后立即把已完成握手的 listener handle 转入 accept queue 并补充新 listener。该 poll 入口由 TCP/UDP 阻塞循环、socket readiness 查询和 /proc/net/tcp 生成路径调用, 因而当前协议栈是协作式驱动, 而不是由独立 NIC 中断线程推进。

8.4 TCP 套接字与并发监听

RespOS 在 smoltcp TCP 状态机之上增加了面向 syscall 并发操作的粗粒度状态。CLOSED、CONNECTING、CONNECTED 和 LISTENING 表达用户可见生命周期，BUSY 则是临时 CAS 中间态，用于防止同一 socket 被两条路径同时执行不可并发的状态转换。

代码片段 8-2 TCP 粗粒度状态的 CAS 提交

```
// os/src/net/tcp.rs (节选)
fn update_state<F, T>(&self, current: u8, new: u8, f: F) -> Result<T, Errno>
where
    F: FnOnce() -> Result<T, Errno>,
{
    match self
        .state
        .compare_exchange(current, STATE_BUSY, Ordering::Acquire,
Ordering::Acquire)
    {
        Ok(_) => {
            let res = f();
            if res.is_ok() {
                self.set_state(new);
            } else {
                self.set_state(current);
            }
            res
        }
        Err(_old) => Err(Errno::EISCONN),
    }
}
```

代码片段 8-2 的关键在于失败时恢复原状态。bind、connect、listen、close 都通过同一入口提交粗粒度转换，从而避免协议句柄已创建而用户状态仍留在另一阶段。




图 8-3 TCP 客户端与服务端生命周期

图 8-3 展示的状态转换由 syscall 操作触发，而协议握手的实际推进依赖下一节所述的协作式轮询。

8.4.1 阻塞、非阻塞与信号中断

TCP 的 connect/accept/send/recv 共用 block_on 模式：先调用 poll_interfaces() 推进协议栈，再尝试一次操作；如果返回 EAGAIN，非阻塞 socket 立即向用户返回，阻塞 socket 则将当前任务标记为可中断等待，登记约 1 ms 的短期 timeout 后切换任务，醒来再重试。

之所以不在 syscall 中持续忙轮询，是因为 listener 等待第一个连接时可能暂时没有其他 ready 任务；如果内核一直在 TCP 循环中占用 CPU，调度器 idle 路径无法推进 sleep/timeout，无关定时任务也会被饥饿。短期阻塞让出 CPU，同时保留轮询式协议栈的实现简洁性。

等待期间会在切换前后检查 real timer、pending signal 和 interrupted 状态，被信号中断时返回 EINTR。注册 blocked 与真正切换之间的信号窗口也会二次检查，避免发送方已标记中断、但尚找不到 blocked queue 条目时产生丢失唤醒。

shutdown(SHUT_RD) 记录接收半边关闭，后续读取返回 EOF；SHUT_WR 记录发送半边关闭并调用 smoltcp close() 推进 FIN 路径，后续写入返回 EPIPE。Drop 是所有权最终落点：普通连接从全局 SocketSet 移除 handle，监听 socket 还由 unlisten 回收 listener 池和 accept queue 中尚未交给用户的所有 handle。

8.4.2 backlog listener 池

RespOS 不把 smoltcp 的单个 listening socket 直接等同于 Linux backlog，因为 smoltcp 中一个 listener 完成握手后会变成该条已连接 socket。在用户态调用 accept 前，原端口就暂时失去可承接后续 SYN 的 listener；多个 client 在同一轮 poll 中到达时，后续连接可能收到 reset。

RespOS 因此将 listen(backlog) 实现为受限 listener 池。backlog 被限制到 1~128，每个端口的 ListenTableEntry 同时维护“仍在监听/握手中”的 listen_handles 和“已连接、等待 accept”的 accept_queue。两个队列总长度不超过 backlog，既预留并发握手容量，又防止恶意大 backlog 无界占用每个 64 KiB 收发缓冲的 TCP socket。

代码片段 8-3 listener 池的容量不变量

```
// os/src/net/listen.rs (节选)
fn replenish_listeners(entry: &mut ListenTableEntry) {
    while entry.listen_handles.len() + entry.accept_queue.len() <
        entry.queue_limit {
        let mut socket = SocketSetWrapper::new_tcp_socket();
        if socket.listen(entry.listen_endpoint).is_err() {
            return;
        }
        let handle = socket_set().lock().add(socket);
        entry.listen_handles.push_back(handle);
    }
}
```

如代码片段 8-3 所示，池中每移出一个已连接 handle，就尽快补入新 listener。这一补充不等用户态 accept 才发生：每次协议 poll 后，promote_ready_listeners 会把 Established handle 转入 accept queue，然后立即补位。

```
listen(backlog=N)
    → 预建 N 个 listener handle (N 限制为 1..128)
    → Interface::poll 完成一条握手
    → Established handle 从 listen_handles 移入 accept_queue
    → 立即补建新 listener
    → accept 取出 handle，所有权转入新 TcpSocket
```

图 8-4 backlog listener 池与 accept queue 的句柄转移

图 8-4 中的 handle 只是 SocketSet 索引，本身不拥有协议对象，因此每条移交路径都明确唯一所有者：监听期属于 ListenTableEntry，accept 成功后属于新 TcpSocket，unlisten 则显式 remove 两个队列中的所有剩余 handle，从而避免重复 remove 和未接受连接泄漏。

该设计来自对真实并发失败的修复。旧实现只有一个 listener，多个 client 并发连接时会随机 reset。2026-08-03 的 RV64 CAgent 回归中，修复后连续三轮不再出现 Connection failed to 127.0.0.1:8080，包括 network 在内的网络责任项稳定通过；当时整体 8/10 的剩余失败已由日志定位到文件系统路径，不被用来扩大网络结论。

8.5 UDP 与 UNIX 域 socket

8.5.1 UDP 数据报

UDP 不需要 TCP 的连接状态机，但仍然管理本地端点、默认对端、端口冲突、阻塞语义和数据报边界。UdpSocket::new 在全局 SocketSet 中创建一个带 256 个 metadata slot、64 KiB 接收字节区和 64 KiB 发送字节区的 smoltcp socket。

bind 检查同地址/端口是否已被现有 UDP socket 占用；端口为 0 时，从 0xc000..=0xffff 循环取候选端口并扫描 SocketSet 验证冲突。因而，当前源码中没有独立 PortManager，端口所有权由存活的协议 socket 直接体现。

表 8-2 对比无连接与保存默认对端两种 UDP 用法。

表 8-2 UDP 两种用法的数据路径

用法	发送	接收	地址语义
无连接	sendto(buf, remote)	recvfrom(buf)	每个数据报单独指定/返回对端
已 connect	send(buf)	recv(buf)	socket 保存默认对端，接收时过滤非匹配端点

未显式 bind 的 socket 在首次发送或 connect 时自动绑定回环临时端口。recvfrom 先使用固定 1528 字节的内核临时缓冲接收，再按用户缓冲长度复制并写回来源地址；协议栈报告数据报超过该临时缓冲时，当前路径将 Truncated 转换为 EAGAIN，因此不能把它表述

为任意长度数据报的完整接收。阻塞 UDP 会在 EAGAIN 时让出 CPU 并检查信号，但当前使用 cooperative yield，没有 TCP 路径的 1 ms blocked-timeout 协议。

8.5.2 UNIX 域 socket

RespOS 为本机 IPC 提供不经过 smoltcp 的 UNIX 域 socket，因为 socketpair 和基于 pathname 的本地服务是 libc、shell 和多进程工具的常见依赖，不需要 IP 报文开销。每个 UnixSocket 持有一个接收字节队列和对端队列引用，单向队列容量上限为 64 KiB；socketpair 直接交叉连接两个对象的队列。

pathname bind 会通过 VFS 创建 InodeType::Socket 节点，同时把路径 key 注册到内核 UNIX_LISTENERS 表；抽象地址只使用内核 key，不创建路径节点。listen 为 key 建立 pending queue，connect 创建与客户队列交叉引用的服务端 UnixSocket 并推入队列，accept 取出该对象。pending queue 上限为 128，监听 socket 关闭时删除对应注册项。

当前 SOCK_STREAM、SOCK_DGRAM 和 SOCK_SEQPACKET 的 UNIX 域数据面都复用字节队列，因而已提供本地传输和 socketpair，但 DGRAM/SEQPACKET 还没有独立保留消息边界的队列语义。这是当前实现的精确边界，因此不将其表述为完整 UNIX datagram/seqpacket 实现。

8.6 网络系统调用与就绪性

RespOS 的网络 syscall 层保持“解析 ABI、获取 socket 对象、调用领域方法、写回结果”的边界。表 8-3 展示已接入的主要接口及其实现重点。

表 8-3 主要 socket 系统调用

类别	系统调用	RespOS 实现重点
创建	socket、socketpair	domain/type/protocol 校验，SOCK_NONBLOCK/CLOEXEC，多 fd 失败回滚
端点与连接	bind、connect、listen、accept/accept4	sockaddr 转换，低端口权限，backlog 传递，新连接 fd 所有权
数据	sendto/recvfrom、sendmsg/recvmmsg、sendmmsg/recvmmsg	通过 MM 逐页 copyin/copyout, iovec 聚合/分散，部分成功返回
查询与控制	getsockname/getpeername、setsockopt/getsockopt、shutdown	长度受限写回, TCP_NODELAY、IP TTL 等有效选项，半关闭语义
等待	read/write、ppoll/pselect6、epoll	通过 FileOp::read_ready/write_ready 统一扫描 socket 可读/可写状态

sendmsg/rcvmsg 会先检查 IOV_MAX=1024 和累计长度溢出，再经 MM 的用户页拷贝路径处理每个 iovec；sendmmsg/rcvmmsg 按消息顺序处理，中途失败时，若前面已有成功项就返回已完成数量，保留 Linux 多消息接口的部分进度语义。控制消息、out-of-band 数据和 error queue 尚未实现，相关 flag 返回明确 errno，而不伪造附加数据。

socket readiness 由 Socket::tcp_poll 先驱动一轮协议 poll，再查询 TCP/UDP/UNIX 对象。TCP 已连接 socket 根据 can_recv/can_send/may_recv/may_send 计算可读可写，listener 根据 accept queue 是否非空可读，UDP 根据数据报缓冲状态判断，UNIX socket 则检查字节队列或 pending queue。这使 socket 能被标准 ppoll/pselect6/epoll 扫描；当前 socket 没有覆盖 FileOp::register_poll_waiter 建立事件推送，因而统一等待层对这类 fd 使用协作式重试，不将其宣称为完全事件驱动的 socket 唤醒。

/proc/net/tcp 也复用同一实时状态。procfs 读取时先 poll 协议栈，再同时收集 ListenTable 中的 listener/未 accept 连接和 SocketSet 中的 TCP socket，转换为 Linux 工具可识别的端点与状态表。这使 ss 等用户工具能观察内核网络状态，无需一份独立的 procfs 镜像缓存。

8.6.1 回环 IPv6 兼容边界

RespOS 接受 AF_INET6 TCP/UDP socket，但当前只对 :: 和 ::1 建立回环兼容：syscall 层将两者分别归一为 IPv4 0.0.0.0 和 127.0.0.1 再进入现有回环路径，写回 sockaddr_in6 时再还原为全零或 ::1。其他 IPv6 地址返回 EADDRNOTAVAIL。

这里的目标是满足只需本地回环的 libc 和应用探测，并不是建立完整的 IPv6 接口地址、邻居发现和路由。smoltcp 启用 proto-ipv6 特性只说明协议代码可编译，不代表 RespOS 已经把它接入设备、地址配置和 ABI 的完整路径。

8.7 与其他模块的协作

网络模块的可用性依赖内存、VFS、调度、时钟和 procfs 的共同语义。这些交互是 socket 在竞赛负载中能正确阻塞、被中断并随进程回收的前提，具体边界见表 8-4。

表 8-4 网络模块的跨模块协作

协作模块	网络使用的能力	关键约束
MM	sockaddr、iovec、数据缓冲和 sockopt 的 copyin/copyout	用户页可能跨页或 lazy/COW，不在 net syscall 中直接解引用
VFS / fd table	Socket ： FileOp、 fd 分 配 、 CLOEXEC、 O_NONBLOCK	descriptor flag 与共享 socket 状态必须维持既有分层
task / signal	可 中 断 阻 塞 、 yield、 blocked registration、 EINTR	检 查 与 入 队 之 间 不 得 丢 失 signal wakeup
timer	TCP 阻塞轮询的短 timeout、 smoltcp poll timestamp	不 在 socket syscall 忙 等 导 致 全 局 timeout 饥饿
procfs	/proc/net/tcp 的动态端点和状态	从实际 listener/socket 生成，不维护会过期的镜像

8.8 功能与设计成果总结

RespOS 网络模块的项目贡献主要位于 smoltcp 之上和之下的工程连接：向上建立 Linux socket ABI、fd/VFS 身份和可中断阻塞语义，向下建立可复用缓冲的 loopback Device，并在中间为 smoltcp 单 listener 建立符合 backlog 用户语义的受限句柄池。表 8-5 汇总这些成果及其当前边界。

表 8-5 网络模块成果与当前边界

方向	已实现的设计成果	证据或边界
TCP loopback	connect/listen/accept/send/recv/shutdown, CAS 状态机，可中断阻塞	net_loopback_smoke 覆盖 fork 客户端与请求/回显；真实外网不在当前数据面内
并发监听	backlog 限制为 1~128, listener 池、accept queue 和 poll 后立即补位	2026-08-03 RV64 CAgent 连续三轮的并发 connect 失败消失；不用 client 硬编码重试掩盖 ECONNREFUSED
UDP loopback	bind/sendto/recvfrom/connect/send/recv, 自动临时端口	net_loopback_smoke 覆盖数据报发送、内容和来源地址
UNIX 域	pathname/抽象 key、socketpair、listen/connect/accept、64 KiB 内存通道	DGRAM/SEQPACKET 当前与 stream 共用字节队列，不宣称完整消息边界
Linux ABI	sockaddr v4/v6/unix、msg/mmsg、主要 sockopt、fd readiness、/proc/net/tcp	ancillary data、OOB/error queue、raw socket 未实现；socket poll waiter 仍为协作式重试
网络层与设备	IPv4 loopback 与 AF_INET6 ::::1 兼容入口	其他 IPv6 地址、路由、virtio-net 与物理网卡数据路径尚未接入

就当前实现而言，网络模块已经形成了一条本地通信闭环：套接字由 fd 持有，协议状态由 smoltcp 驱动，阻塞过程与调度和信号协作，并发握手由 listener 池维持 backlog 容量，close 后再回收协议句柄。章节中列出的边界对应当前实际接入的数据路径，而不是第三方库本身的功能列表。

9. 硬件抽象层与架构适配

本章介绍 RespOS 在 RISC-V64 和 LoongArch64 上的架构适配，以及页表、trap、任务切换、时钟和启动流程的统一边界。

RespOS 的双架构支持采用“公共内核逻辑 + 架构目录特化”的设计。任务管理、内存管理、文件系统和系统调用等模块使用统一的公共代码；启动入口、寄存器访问、页表操作、异常返回、上下文切换和时钟触发等必须依赖硬件的部分，则分别位于 `os/src/arch/rv64/` 和 `os/src/arch/loongarch64/`。

当前架构层不是一套完全由 trait 组成的独立 HAL 库，而是由条件编译、模块重导出、同名函数和相同的数据结构约定共同形成的适配边界。`os/src/arch/mod.rs` 根据 `target_arch` 选择具体实现并重新导出，使公共代码可以调用 `read_mmu_token`、`write_mmu_token`、`sfence`、`set_next_ti_trigger` 等统一入口，而不直接散落 CSR、汇编指令和硬件寄存器假设。

9.1 架构适配的整体结构

9.1.1 一套公共调用链，两套底层实现

RespOS 的架构目录按照启动、内存、trap、task、timer 和 interrupt 等职责组织。两套目录提供相近的模块接口，但在内部使用各自架构的寄存器和汇编实现：




图 9-1 RespOS 双架构适配结构

这种结构的关键不是让两个架构的代码完全相同，而是让公共模块只依赖稳定的语义接口。例如，公共内存管理只需要“写入当前页表根并刷新地址转换缓存”，不需要知道

RV64 使用 satp、sfence.vma，还是 LoongArch 使用 PGDL/PGDH 和 invtlb。架构层负责把同一语义翻译成对应指令序列。

9.1.2 双架构差异总览

适配维度	RISC-V64	LoongArch64	公共抽象
内核入口	OpenSBI 进入 S-mode, 传入 hart id 和 FDT opaque	QEMU/固件进入低地址直映入口	enter_main → rust_main_high
当前计数器	time CSR/计数器	rdtime.d	get_time、频率转换和下一次触发
地址转换根	satp	PGDL/PGDH	read_mmu_token、write_mmu_token
页表遍历	硬件 Sv39 遍历	TLB refill 汇编使用 lddir/ldpte	map/unmap/query/protect
用户 trap 状态	stvec、sstatus、sepc、scause、stval	EEntry、PRMD、ERA、ESTAT、BADV	TrapContext 与公共 trap handler
异常返回	sret	ertn	restore 汇编后的用户态返回
任务页表切换	写 satp 后 sfence.vma	同时写 PGDL/PGDH 后刷新 TLB	TaskContext 保存地址空间 token
外部设备形态	QEMU virt 的 MMIO 设备	QEMU LoongArch 的 PCI 设备	drivers 层统一设备操作

表 9-1 RV64 与 LA64 的架构差异及统一接口

9.2 地址空间与页表适配

9.2.1 共享高半区内核模型

两个架构最终采用相同的高半区内核地址模型。公共内核代码通过统一的 KERNEL_BASE 访问内核映像、内核堆和内核设备映射；创建用户地址空间时，架构层提供 PageTable::from_kernel()，复制内核根页表中属于内核高半区的部分。

这样，MemorySet 可以在两种架构上复用相同的 VMA、页帧和映射逻辑。用户地址空间的差异主要集中在页表项编码、地址转换寄存器和 TLB 刷新，不会扩散到 COW、lazy allocation、file-backed mapping 等上层机制。

9.2.2 RISC-V Sv39 页表

RISC-V 页表采用 Sv39 三级结构。PageTable 保存根页表物理页号和由 FrameTracker 管理的页表页帧；映射时按 VPN 的三级索引逐级创建中间页表，叶页表项保存物理页号和读写执行权限。token() 将根页表物理页号编码为 satp，任务切换时由汇编保存和恢复该 token。

RISC-V 还为内核 direct map 提供了大页映射入口。启动阶段的 early page table 先建立能够覆盖 QEMU 最大可达内存窗口的映射，之后由 FDT 识别实际 RAM 末址，并由正式 frame allocator 严格按实际内存上限分配。这样既能在早期读取固件提供的设备树，又不会把预留的最大窗口误认为真实物理内存。

9.2.3 LoongArch 页表与 TLB refill

LoongArch 的页表同样采用三级、4 KiB 页粒度的结构，但硬件地址转换通过 TLB 完成。发生 TLB miss 时，tlb_refill.S 使用 PGD 根地址和 lddir、ldpte 指令读取多级页表项，装载偶数页和奇数页的 TLBLo 后执行 tlbfill；如果目录项无效，则构造无效 TLB 项并返回异常路径。

LoongArch 的 read_mmu_token 返回 PGDL 根地址，write_mmu_token 同时更新 PGDL 和 PGDH，并设置 ASID 和页表根同步状态。任务切换汇编也保存一个根 token，恢复时写入两个根页表寄存器并刷新 TLB。公共代码因此只看到“切换地址空间并使地址转换状态生效”，不需要处理两个根寄存器的细节。

9.2.4 页表操作的统一语义

两套 PageTable 都提供创建、映射、解除映射、查询、修改权限和替换页表项等操作。公共 MemorySet 依靠这些操作实现：

```
MemorySet
├─ 创建 VMA 和物理页帧
├─ PageTable::map / unmap
├─ page fault 时 query / 建立叶映射
├─ COW 时 replace_pte / modify_pte
└─ 地址空间切换时 token / sfence
```

图 9-2 公共内存管理与架构页表实现的关系

页表页帧由页表对象持有并自动追踪。进程退出或地址空间替换时，页表页帧不会立即在任意执行上下文中复用，而是经过有限的 quarantine 队列延迟回收，避免硬件仍可能观察旧页表根时发生页表页帧复用。这一机制在两套架构中保持相同语义，只在页表根和刷新指令上有所不同。

9.3 Trap 与特权级切换

9.3.1 统一的 trap 三阶段

两种架构的 trap 入口虽然使用不同的 CSR 和汇编语法，但都遵循相同的三阶段流程：

```
entry: 硬件保存原因和返回地址，汇编保存寄存器
      │
      ▼
handler: 构造 TrapContext，进入公共 Rust trap 分发
```





图 9-3 双架构 trap 处理的公共流程

RISC-V 从 stvec 进入 trap.S, 硬件提供 sepc、scause 和 stval; LoongArch 从 EEntry 进入对应入口, 硬件提供 ERA、ESTAT 和 BADV。两条路径随后都把通用寄存器和返回地址组织成 TrapContext, 交给公共 syscall、page fault、timer 和 signal 逻辑处理。

9.3.2 TrapContext 的统一字段与架构差异

TrapContext 表示一次用户态执行被内核接管时需要保存的完整状态。两个架构都保存 32 个通用寄存器、用户返回 PC、用户栈指针以及返回特权级所需的状态, 但字段形式不同:

内容	RISC-V64	LoongArch64
通用寄存器	x[32], ABI 参数使用 a0-a7	x[32], ABI 参数使用 r4-r11
返回地址	sepc	era
前一特权级	sstatus.SPP	prmd.PPLV
返回中断状态	sstatus.SPIE/SIE	prmd.PIE
浮点状态	f[32]、fcsr	当前 TrapContext 不单独保存浮点寄存器
公共访问	get_a0/set_a0/get_sp/set_sepc 等	提供同名语义访问方法, 内部映射到不同寄存器编号

表 9-2 两种架构的 TrapContext 对照

公共 syscall 代码通过 get_a0、set_a0、get_sepc 等语义方法访问上下文, 不直接读取 x[10] 或 x[4]。例如, RISC-V 的 syscall 返回值写入 x[10], LoongArch 则写入 x[4], 但公共代码只需要调用 set_a0。这使 Linux ABI 参数处理和系统调用分发逻辑能够跨架构复用。

9.3.3 返回用户态的安全顺序

RISC-V 的用户态返回路径包含一个必须保持的安全顺序: 恢复过程中先清除 SIE, 保持 stvec 指向内核 trap 入口, 完成通用寄存器、浮点寄存器和 sscratch 等状态恢复后, 才切换到用户 trap vector, 最后执行 sret。用户态中断使能由 sstatus.SPIE 在 sret 时恢复。

如果提前恢复用户态 trap vector 或提前打开 SIE, timer 可能在 sscratch 和寄存器恢复尚未完成时重入用户 trap 入口, 破坏 trap 保存约定。该顺序同时适用于普通 syscall 返回、exec 初始上下文和 signal sigreturn, 因此被放在架构汇编层统一保证。

LoongArch 返回路径则恢复 PRMD、ERA 和通用寄存器, 最后通过 ertn 返回。两者的返回指令不同, 但共同遵守“完成内核上下文恢复后再恢复用户态特权状态”的原则。

9.4 任务上下文与调度切换

9.4.1 TaskContext 与 TrapContext 的分工

RespOS 将用户态异常上下文和内核态调度上下文分开。TrapContext 保存用户程序被中断时的完整执行状态，供 syscall、信号和 page fault 处理使用；TaskContext 只保存一次内核任务切换所需的调用约定寄存器、内核栈位置和地址空间 token，供 scheduler 的 `__switch` 使用。



图 9-4 TrapContext 与 TaskContext 的职责分工

这种分工避免每次内核调度都复制完整用户寄存器集合。任务被阻塞或主动让出 CPU 时，架构汇编只保存当前内核执行点能够继续运行所需的最小上下文；任务重新获得 CPU 后，从自己的内核栈恢复并继续执行。

9.4.2 两套 switch.S 的共同布局


RISC-V 和 LoongArch 的 switch.S 使用相同的抽象参数：下一个任务的内核栈指针和当前任务控制块中的栈指针位置。两套汇编都保存 ra、tp、callee-saved 寄存器和当前地址空间 token，然后恢复下一个任务的对应内容，切换栈并返回。

差异集中在寄存器名称、加载存储指令和地址转换刷新指令：RISC-V 写入 satp 后执行 sfence.vma；LoongArch 写入 PGDL/PGDH 后执行数据屏障、TLB invalidate 和指令屏障。调度器不需要知道这些差异，因此任务调度和阻塞唤醒逻辑保持在公共 task 模块中。

9.5 启动流程适配

9.5.1 公共启动阶段

两个架构最终都会进入 `rust_main_high`，公共启动顺序为：



```

└─ 初始化多核 idle task (RV64)
└─ 开启 timer interrupt 并设置第一次触发
└─ 进入 task::run_tasks

```

图 9-5 双架构公共启动阶段

公共启动顺序保证了依赖关系：trap 必须在处理异常前初始化，内存必须在创建任务和网络对象前可用，initproc 入队后才开始调度，timer interrupt 则在调度器准备好之后开启。

9.5.2 RISC-V 启动路径

RISC-V _start 从 OpenSBI 进入 S-mode，获得 hart id 和 FDT opaque 参数。汇编入口根据 hart id 选择独立 early stack，写入 boot page table 的根到 satp，执行 sfence.vma 后跳转到 enter_main。Rust 入口随后完成 BSS 清零、读取 FDT 中的实际内存范围，并进入公共启动阶段。

RISC-V 的启动页表预先覆盖 QEMU virt 的最大可达内存窗口，以保证 boot hart 能访问 OpenSBI 放置在 RAM 顶部的 FDT；正式内存管理仍依据 FDT 的实际 reg 范围建立 frame allocator 和 kernel direct map。这体现了“早期可达窗口”和“真实资源上限”的明确分工。

9.5.3 LoongArch 启动路径

LoongArch _start 进入时仍处于低地址直接映射环境。入口先保留当前执行段所需的 DMW 配置，再开启低地址 DMW，使早期代码可以访问低物理地址；随后 enter_main 跳转到 Rust rust_main。在公共启动前，LoongArch 建立覆盖早期内核镜像和内核堆的临时高地址页表，开启分页并跳转到共享高半区内核入口。

这一过渡解决了两个地址模型之间的切换问题：启动入口可以依赖固件提供的低地址直映，公共内核则可以从一开始使用与 RISC-V 相同的高半区地址约定。进入正式页表后，LOW_DIRECT_MAP_ACTIVE 等架构状态用于记录早期直映是否仍在使用的，避免公共代码误把启动阶段映射当成最终地址空间模型。

9.6 功能与设计总结

RespOS 的硬件抽象与架构适配可以归纳为表 9-3：

设计成果	实现方式
公共内核跨架构复用	arch/mod.rs 使用条件编译选择架构实现，并通过同名入口向公共模块提供统一语义
双架构地址空间	两个架构共享高半区内核模型，分别封装 satp 或 PGDL/PGDH、页表遍历和 TLB 刷新
统一 trap 处理	架构汇编保存不同硬件上下文，公共 Rust handler 复用 syscall、page fault、timer 和 signal 分发
统一任务切换	TaskContext 采用相同抽象布局，switch.S 仅特化寄存器保存、页表根切换和地址转换刷新
双架构启动	RV64 从 OpenSBI/FDT 进入，LA64 从低地址直映过渡到高半区，最终进入同一公共初始化顺序
架构安全约束	在 arch 层保证 trap return 顺序、页表根切换、TLB 刷新和早期映射过渡的正确性

表 9-3 硬件抽象层与架构适配的设计成果

这里的做法不是把 RISC-V 和 LoongArch 的硬件差异全部抹平，而是把它们集中在入口、寄存器、页表、trap 汇编和任务切换等边界。公共内核围绕统一的任务、地址空间和系统调用语义运行，架构层再把这些语义落实到各自的指令集和特权体系上。

10. 设备驱动

本章回答：设备驱动如何抽象？virtio 块设备和网卡如何接入内核？

10.1 概述

RespOS 的驱动模型通过统一的 Device trait 和 Disk trait 抽象块设备，通过 virtio 框架支持 virtio-blk 和 virtio-net 两种虚拟设备。设备驱动层位于 HAL 之上——HAL 提供 MMIO 地址映射和中断注册能力，驱动层负责设备初始化和数据传输协议。

【建议检查的代码】 `os/src/drivers/mod.rs`, `os/src/drivers/device.rs`

10.2 块设备驱动

virtio-blk 设备初始化。 virtio-blk 是 QEMU 提供的高性能虚拟块设备。初始化流程为：通过 MMIO 地址探测 virtio 设备 → 读取设备 ID 确认是块设备 → 协商 features（如 VIRTIO_BLK_F_RO、VIRTIO_BLK_F_FLUSH 等）→ 分配一个 virtqueue → 完成驱动初始化。

块读写接口。 Disk trait 提供 `read_block(block_id, buf)` 和 `write_block(block_id, buf)` 两个核心操作。每个请求构造一个 virtio-blk request (type + sector + data)，填入 virtqueue descriptor，通知设备后轮询等待响应。数据直接从 descriptor 对应的物理内存区域传输，无需额外拷贝。

与文件系统的对接。 ext4 后端的 BlockDeviceImpl 实现了 lwext4 需要的 ext4_blockdev_iface 回调表——包含 `dev_open`、`dev_read`、`dev_write`、`dev_close`、`dev_seek` 五个函数。这些函数将 lwext4 的块操作翻译为 Disk trait 调用，使 lwext4 能透明使用 virtio-blk 设备。

双架构差异。 RISC-V 下 virtio 设备通过 MMIO 地址直接访问；LoongArch 下某些 virtio 设备通过 PCI 总线连接，需要额外的 PCI 枚举步骤。

【建议检查的代码】 `os/src/drivers/virtio/`, `os/src/drivers/disk.rs`

【建议准备的图】用户 I/O → VFS → ext4 → page cache → Disk trait → virtio-blk 调用链

10.3 网卡驱动

virtio-net 设备的初始化流程与 virtio-blk 类似，但需要两条 virtqueue（发送队列和接收队列）。NetDevice trait 抽象了网卡的通用接口：poll() 驱动数据收发，transmit() 发送数据包，receive() 读取已到达的数据。

数据收发与 smoltcp 协议栈的集成点在于：设备 poll 时将接收到的原始以太网帧注入 smoltcp 的 Interface 对象，smoltcp 内部完成 IP 重组、TCP 状态机处理和 socket 投递；发送方向则从 smoltcp 获取待发送帧并填入 virtqueue。

10.4 串口驱动

NS16550A UART 是 x86/ARM/RISC-V 平台通用的串口控制器。RespOS 通过 MMIO 地址映射访问 UART 的寄存器（THR/RBR 用于收发、LSR 用于状态查询）。串口是内核早期启动阶段唯一的调试输出通道——在 console 初始化完成前，所有 println! 通过 UART 逐字节输出。

10.5 设备树与设备发现

设备树（Device Tree）是 RISC-V 平台描述硬件拓扑的标准方式。它是一个树形数据结构，描述 CPU 核心数、内存基址和大小、外设 MMIO 地址等关键信息。RespOS 在启动时解析 FDT，提取物理内存范围和 virtio 设备的 MMIO 基址。LoongArch 2K1000 平台不使用设备树，改为板级固定配置——内存大小和外设地址在 board/2k1000.rs 中硬编码。

【建议检查的代码】架构相关的设备树解析代码，os/src/arch/*/config/board.rs

11. 项目参考、AI 使用与第三方代码

RespOS 的实现参考并不是从某个项目整体移植而来，而是分散在不同的内核机制中。RocketOS 和 del0n1x 是开发过程中查看较多的参考实现；Linux、Phoenix-RTOS 等项目以及 Unix 接口规范，主要用来对照对象关系和用户态行为。下面按照实现主题说明这些参考在 RespOS 中具体落到了什么地方。

11.1 按实现主题整理的参考

11.1.1 文件系统对象与 ext4 接入

文件系统是参考内容最集中的部分。RocketOS 对 VFS 的分层给了我们比较直观的参照：路径、目录项、inode、打开文件和文件描述符分别承担不同职责。RespOS 采用了相近的边界，但根据自己的 ext4 后端重新组织了生命周期。FdTable 管理进程看到的整数 fd，FileOp 保存一次打开操作的状态，Path 和 Dentry 处理命名空间，InodeOp 则描述后端文件对象提供的能力。

del0n1x 主要参考了 lwext4 的接入方式，包括 Rust 封装、块设备适配和 C 接口调用。RespOS 中，Disk 把 virtio-blk 的块读写和 flush 转换为 lwext4 所需的设备接口，Ext4Inode 实现 InodeOp，把路径型 ext4 操作接到 VFS；lwext4 的错误码会转换为内核 Errno，共享的底层调用由 EXT4_OP_LOCK 保护。inode、页缓存和路径对象还需要共同处理打开计数、rename 以及 unlink 后的 orphan 文件。

Linux VFS 更多是语义上的参照。例如，打开文件的共享偏移量、目录项和 inode 的区分、unlink 后已打开文件仍可访问，以及 mmap 与页缓存的关系，都影响了 RespOS 的对象设计。RespOS 没有直接引入 Linux 的实现，相关代码集中在 os/src/fs/vfs/、os/src/fs/ext4/、os/src/fs/file.rs 和 os/src/fs/fdset.rs。

11.1.2 地址空间、页表与内存映射

内存管理部分参考了成熟内核对地址空间的划分方式，也结合了 RocketOS 的教学型页表和映射组织。RespOS 用 MemorySet 表示一个地址空间，用 MapArea 表示其中的一段连续映射；mmap、munmap、mprotect、mremap 和缺页处理都围绕这组对象展开。

Linux 的 VMA 思路帮助我们区分地址范围、映射权限和实际驻留页面，RocketOS 的实现则提供了页表和映射区域组织方面的具体参照。RespOS 在 fork 时通过共享物理页、修改页表权限和写保护异常实现 COW，exec 时重新建立地址空间；文件映射则把 VMA、FileOp、页缓存和缺页读入联系起来。页表项、页帧分配和文件映射缓存仍由 RespOS 自己实现，尤其是 LoongArch64 的页表接口不能直接沿用 RISC-V 代码。

11.1.3 进程、线程与调度

进程管理以 Linux 的 task/线程组模型作为语义参照，以 RocketOS 的任务控制块、上下文切换和调度器组织作为实现层面的参考。RespOS 没有把进程和线程拆成两套控制块，而是用 TaskControlBlock 统一表示可调度任务，再通过 tid、tgid 和资源共享关系表达差异。

fork、clone、execve、exit 和 wait 的用户态行为参考 Linux ABI，但资源复制、共享和回收由 RespOS 的任务、地址空间、fd 表和信号对象共同完成。内核栈、保存现场和上下文切换借鉴了 RocketOS 的分层方式，同时为 RISC-V64 和 LoongArch64 分别实现入口汇编和 TaskContext。调度器没有照搬 Linux CFS，而是采用分层固定优先级队列，统一承载实时任务、普通任务和后台任务。多核部分参考了 RocketOS 对 hart 启动、per-CPU 状态和 SBI 接口的划分，但调度队列、初始化和唤醒协议仍按 RespOS 当前的数据结构实现。

Linux 在这里主要回答“进程和线程对用户应该表现为什么样”，RocketOS 则帮助确认任务控制块和架构入口可以怎样组织；具体调度策略以及资源生命周期属于 RespOS 自己的实现。

11.1.4 信号、trap 与用户态返回

信号机制参考了 RocketOS 对 pending、信号处理函数、用户态 trap context 和 sigreturn 的连接方式，同时以 Linux 的信号屏蔽、默认动作、handler 返回和线程组语义作为行为对照。RespOS 将待处理信号、阻塞掩码和处理函数表放在相应的线程或线程组对象中，投递信号时构造用户态上下文，执行 sigreturn 时再恢复被打断的现场。

trap 入口按照架构分别保存寄存器和异常信息。公共 syscall、信号投递和任务返回逻辑不直接依赖某一架构的寄存器编号，RISC-V64 与 LoongArch64 只在上下文结构、入口汇编和返回指令处适配。这样既保留了 Linux 风格的用户态行为，也没有把 RocketOS 的单架构上下文布局直接带入双架构内核。

11.1.5 IPC、同步与阻塞唤醒

管道、futex、poll/epoll 以及信号等待等机制，主要参考 Linux 对阻塞、唤醒和 fd readiness 的用户态语义。实现时需要把等待条件和任务状态联系起来：任务阻塞前加入等待队列，唤醒后重新检查条件，任务退出或 fd 关闭时移除等待关系，避免留下悬挂引用。

RespOS 没有直接套用某个项目的 IPC 实现，而是将等待队列、任务状态、FileOp 和 trap 返回路径组合起来，使 pipe、socket、timerfd 等对象可以使用相近的阻塞模型。锁边界、错误回滚和多核唤醒则根据各模块现有的数据结构分别处理。

11.1.6 网络 socket 与设备接口

网络部分以 Linux socket ABI 作为用户态接口参照，以 smoltcp 提供的协议状态机作为协议实现基础。RespOS 自己完成了两者之间的连接：Socket 通过 FileOp 接入 fd 模型，

syscall 层负责 sockaddr、iovec 和 sockopt 等 ABI 结构, TCP/UDP 状态由 smoltcp 管理, 当前设备侧主要使用 loopback device。

设备和架构适配参考 RISC-V、LoongArch 的架构手册以及 RocketOS 的启动和 SBI 分层方式。公共 syscall、任务和内存逻辑通过统一接口使用 TrapContext、页表、时钟和中断能力, CSR、入口汇编、TLB 刷新和特权级返回则留在各自的架构目录中。

这些参考项目在 RespOS 中提供的是设计对照, 而不是可以替代本项目的现成实现。最终采用的字段、锁、错误路径和跨模块调用, 仍以当前仓库源码和测例结果为准。

11.2 AI 工具的使用方式

项目开发过程中使用过 AI 工具, 主要用于代码检索、调用链梳理、错误日志分析、方案讨论和文档整理。它更像一个辅助检索和讨论工具, 不能代替代码修改者对实现和测试结果的确认。

在代码理解方面, AI 可以根据文件、符号和调用关系整理模块结构, 但字段含义、调用者和错误路径需要回到当前源码核对。遇到 QEMU 串口、GDB 栈或测试日志中的问题, AI 可以帮助归纳可能原因, 最终仍要通过源码追踪、最小复现或再次运行验证。对于锁边界、对象生命周期和跨架构实现, AI 可以提供方案比较, 但是否采用由负责成员结合现有数据结构决定。文档整理时也以源码和实际测例为准, 无法证明的结论不会直接写入正文。

人工审查主要关注三类问题: 是否破坏对象所有权, 是否在错误路径留下半完成状态, 以及是否在中断或多核环境下引入竞态。硬件行为、测试结果和兼容性结论如果没有源码或运行证据, 也不会仅凭 AI 的推测确认。

11.3 第三方代码与依赖

RespOS 将需要离线构建的部分依赖放在 vendor/ 中, 并在 os/Cargo.toml 中使用路径依赖。这样可以固定版本, 避免比赛环境临时访问网络, 也方便一并检查许可证文件。

lwext4_rust 位于 vendor/lwext4_rust/, 在 os/src/fs/ext4/ 中使用。它通过 C FFI 提供 ext4 的文件和目录操作, RespOS 在其上实现 Disk 适配、Ext4Inode 和超级块封装, 并接入 errno、缓存、rename 和 orphan 语义。

smoltcp 位于 vendor/smoltcp/, 用于 TCP/UDP/IP 协议状态机和 socket 缓冲。RespOS 在其上补充 loopback device、socket 的 FileOp 实现、Linux socket ABI、阻塞轮询和 listener 池。

riscv 位于 vendor/riscv/, 为 RV64 提供 CSR 和底层指令的 Rust 封装, 在 trap、页表、SMP 和时钟实现中使用。virtio-drivers 提供 virtio 设备访问基础, 当前主要用于 virtio-blk 的设备初始化、中断和块设备访问; 网卡侧保留了设备层适配基础, 网络数据面目前以 loopback 接口为主。sbi-rt 用于调用 RISC-V 的 SBI timer、IPI 和 RFENCE 服务。

当前仓库记录的 vendored 版本和许可证文件位于 vendor/README.md 及各依赖目录。比如, lwext4_rust 保留了 GPLv2 许可证文件, smoltcp 保留了 0BSD 许可证文件, riscv 的来源和许可说明记录在其 README 中。发布文档或代码时, 应以对应目录中的许可证原文和当前依赖版本为准。

11.4 资料与引用

项目参考的资料主要包括 RocketOS 和 del0n1x 的公开源码及项目文档, lwext4、lwext4_rust、smoltcp 和 RISC-V 相关 crate 的源码与许可证, RISC-V/LoongArch 架构手册, 以及比赛提供的用户态测例和 ABI 说明。

这些资料承担的作用并不相同: 参考项目帮助理解设计和实现路径, 第三方库提供基础能力, 架构手册用于确认硬件语义, 比赛测例用于检查用户态可观察行为。RespOS 的具体实现、修改和测试结果仍以本仓库源码和生成日志为准。

12. 总结与展望

RespOS 的实现最终落在一条完整的用户态执行链上：架构入口负责启动和建立最初的运行环境，任务模块负责创建与调度，trap 连接用户态和内核态，内存与文件系统提供程序运行所需的资源，IPC、信号、时钟和网络模块再处理同步、通信与 I/O。

12.1 项目成果

在架构适配方面，RespOS 已经支持 RISC-V64 和 LoongArch64 的启动、页表、trap、任务切换和时钟。公共内核代码负责任务、内存、文件和系统调用等通用逻辑，硬件相关差异集中在 arch/ 目录中处理。

在进程管理方面，内核使用统一的 TaskControlBlock 表示可调度任务，能够承载进程和线程创建、exec、wait、退出、调度以及 RV64 SMP 等功能。fork、clone 和线程创建之间的区别，主要通过地址空间、文件描述符表、信号状态等资源是否共享来表达。

内存管理已经形成了以 MemorySet 为中心的地址空间模型，包含 VMA、PTE、页帧、lazy allocation、COW、ELF 装载和文件映射。地址范围、硬件页表映射和物理页所有权分别由不同对象维护，缺页时再根据映射类型建立实际页面。

文件系统部分建立了 VFS、ext4、procfs、devfs、挂载、namei、dentry cache、page cache 和 fd 生命周期。FileOp 将普通文件、管道、socket、timerfd 和部分特殊文件接入统一的打开文件接口，InodeOp 则把不同后端的文件操作收敛到 inode 层。

IPC 与信号模块实现了信号、管道、futex 和 System V 共享内存。它们共同依赖任务的等待与唤醒机制，在阻塞、超时、信号打断和任务退出同时发生时，需要通过明确的完成协议决定哪个路径最终生效。

时钟模块提供了双架构时钟源，并实现 nanosleep、interval timer、POSIX timer 和 timerfd。各类时间服务都围绕 deadline 组织，再由 timer trap、调度器和等待队列完成到期唤醒。

网络模块在 smoltcp 的基础上实现了 loopback TCP/UDP、UNIX 域 socket、Linux socket ABI 和并发 listener 池。RespOS 自己补上了 socket 与 fd 的关系、阻塞和 poll 语义，以及 listener 句柄在 listen/accept 之间的管理。

这些功能并不是互相独立的。fork 会同时涉及 TCB、MemorySet、FdTable 和信号状态；exec 要在旧地址空间中完成必要的线程静止，再提交新的 ELF 映像；文件映射则把 VMA、PageCache 和 FileOp 的读写路径连接起来。项目中反复使用的 prepare/commit、引用计数、锁外 I/O 和安全点，都是为了解决这些跨模块操作中的所有权和失败问题。

12.2 实现过程中的收获

首先，内核对象的身份需要尽早划清。TCB 是可调度的执行单元，TrapContext 是用户态返回现场，TaskContext 是内核切换现场；VMA 表示地址空间承诺，PTE 表示硬件映射，页帧表示物理所有权。文件系统中的 FdEntry、FileOp、Path、Dentry 和 InodeOp 也分别对应不同的生命周期。对象边界明确之后，fork、dup、exec 和回收路径才有比较稳定的实现基础。

其次，失败路径和并发路径不能等正常功能完成后再补。vfork 的父任务登记顺序、exec 的 sibling 静止、futex 的 single-winner、共享文件映射的锁外写回以及网络 listener 的句柄移交，都需要在设计阶段明确状态转换。只实现一次成功调用还不足以支撑真实的 libc、工具链和多线程程序。

最后，双架构支持并不意味着把所有底层代码写成相同形式。RespOS 采用公共语义加架构特化的方式：公共模块只依赖页表切换、上下文访问和时钟读取等稳定接口，CSR、入口汇编、TLB 刷新和特权级返回留在架构目录中。这样既减少了重复代码，也更容易判断一个问题属于公共逻辑还是硬件适配。

12.3 构建与复现入口

内核构建使用仓库中的脚本。准备环境时，可以先获取比赛镜像：

```
bash scripts/get_img.sh
```

两种架构可以一起构建，也可以分别构建：

```
make all
make build-rv
make build-la
```

运行 QEMU 测试时使用：

```
make rv
make la
```

构建产物是仓库根目录下的 kernel-rv 和 kernel-la，运行日志默认分别写入 rv-output.txt 和 la-output.txt。连续切换架构时，应确认使用了对应的 Cargo 配置，避免两个构建过程同时修改共享配置文件。

决赛文档由 Markdown 生成 Typst，再由 Typst 输出 PDF：

```
bash docs/决赛文档/build.sh
```

正文源文件位于 docs/决赛文档/markdown/，chapters/ 是自动生成的中间文件，不应直接修改。

12.4 后续工作

后续工作首先是继续完善双架构验证。RV64 的 SMP、共享地址空间和工具链压力测试已经积累了较多专项经验，下一步需要用同样的方法覆盖 LoongArch64，并把启动问题、功能问题和并发问题分别记录和复现。

地址空间和文件映射还可以继续扩展。swap、通用页面回收、更完整的 file-backed loader 语义，以及共享映射在文件截断和失效时的处理，都可以建立在现有 VMA、PTE 和 backing 模型上。

并发性能方面，当前全局调度队列、namei 修改锁和部分文件后端锁优先保证状态一致性。后续应先结合实际压力测试确定瓶颈，再考虑 per-CPU 队列、缓存粒度和锁顺序等优化，避免为了追求形式上的并发而破坏已有协议。

Linux ABI 和 IPC 仍有补充空间，例如 SA_RESTART、实时信号排队、消息队列、semaphore、更多 socket 选项和更完整的 UNIX 域消息边界。这些功能可以继续沿用当前的任务、等待队列、FileOp 和信号对象，而不必重新建立一套独立框架。

网络和设备数据面也可以继续扩展。当前网络重点是 loopback 和用户态可观察的 socket 语义，后续可以完善 virtio-net、真实网卡收发、IPv6 地址配置和路由，同时继续统一设备文件与驱动接口。

12.5 结语

RespOS 从用户态启动和基础系统调用出发，逐步扩展到双架构、进程生命周期、虚拟内存、文件系统、进程通信、时钟和网络。项目的主要成果不只是增加了系统调用，而是建立了这些模块之间可以配合工作的对象和协议：任务能够创建、阻塞、唤醒和回收，地址空间能够按需建立和修改，文件和 socket 能够沿统一的 fd 边界使用，硬件差异也被限制在架构层。

当前实现仍有可以完善的地方，但已经形成了较完整的内核骨架和多模块协作路径。后续无论是补充 ABI、优化并发，还是扩展设备和网络，都可以在现有边界上逐步推进。